



(12) 发明专利申请

(10) 申请公布号 CN 112231193 A

(43) 申请公布日 2021.01.15

(21) 申请号 202011431810.4

(22) 申请日 2020.12.10

(71) 申请人 北京必示科技有限公司

地址 100083 北京市海淀区中关村东路8号
东升大厦B座516

(72) 发明人 张文池 隋楷心 程博

(74) 专利代理机构 北京华创智道知识产权代理
事务所(普通合伙) 11888

代理人 彭随丽

(51) Int.Cl.

G06F 11/34 (2006.01)

G06K 9/62 (2006.01)


权利要求书3页 说明书10页 附图6页

(54) 发明名称

时序数据容量预测方法、装置、电子设备及
存储介质

(57) 摘要

本发明涉及计算机技术领域,公开了一种时序数据容量预测方法、装置、电子设备及存储介质,所述方法包括:对时序数据进行预处理;所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种;提取时序数据的特征并判断所述时序数据是否具有周期性特征,输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告;若所述时序数据不具有周期性特征:将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。本发明能够自动判断时序数据的类型,根据不同类型的时序采用不同的模型,并且能够有相对较快的运行速度。



1. 一种时序数据容量预测方法,其特征在于,所述方法包括:
对时序数据进行预处理;所述预处理至少包括异常点剔除、时序数据缺失段长度判断与时序数据缺失段修复其中的一种;
提取时序数据的特征并判断所述时序数据是否具有周期性特征;
若所述时序数据具有周期性特征:
对预处理后的时序数据进行概念漂移检测确定训练集范围;
将所述训练集和提取的时序数据特征输入周期性预测模型,其中对历史节假日数据进行轮廓的回归保存以得到节假日效应;
输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告;
若所述时序数据不具有周期性特征:
将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;
在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。
2. 如权利要求1所述的时序数据容量预测方法,其特征在于,采用k倍标准差阈值算法对异常点进行剔除,其中所述标准差为归一化中位数绝对偏差。
3. 如权利要求1所述的一种时序数据容量预测方法,其特征在于,若时序数据缺失段长度超出设定长度,则不对此段时序数据进行修复;若时序数据缺失段长度未超出设定长度,采用线性插值的方法对此段时序数据进行修复,同时完成时间戳调整。
4. 如权利要求1所述的时序数据容量预测方法,其特征在于,所述时序数据的特征至少包括周期性、数据粒度、数据容量变化类型、数据变化上下界、数据时间范围、节假日数据和非节假日数据中的一种。
5. 如权利要求1所述的时序数据容量预测方法,其特征在于,判断所述时序数据是否具有周期性特征包括:
对于节假日数据,使用其前或后自然时间段对应位置数据代替;
预设半自然时间段与自然时间段的偏移情况,分别计算对应的自相关系数,其中剔除半自然时间段和自然时间段自相关系数最差的时间;
若自然时间段自相关系数高于参考阈值,则判断时序数据存在周期性,所述参考阈值高于半自然时间段自相关系数的3倍。
6. 如权利要求1所述的时序数据容量预测方法,其特征在于,对预处理后的时序数据进行概念漂移检测确定训练集范围包括:
基于最后多个自然时间段内最后多个时间范围的平均异常程度、异常时间槽比例和时间戳补正计算异常分数;
判断所述异常分数最大处异常时间槽比例是否超出阈值,若超出,则判断发生概念漂移,以此多个自然时间段后的时序数据作为训练集。
7. 如权利要求1所述的时序数据容量预测方法,其特征在于,对历史节假日数据进行轮廓的回归保存以得到未来节假日效应包括:
提取历史节假日前时间段的高百分位数和低百分位数;

将历史节假日分类为节假日值数据和节假日残差数据；

基于所述分类对历史节假日前时间段的起点到历史节假日后相同时间段的终点的时序数据进行轮廓的回归保存。

8. 如权利要求7所述的时序数据容量预测方法，其特征在于，输出包括节假日效应的预测结果包括：

对于平常日数据，根据所述训练集的统计分布特征确定似然函数参数关系；

基于似然函数参数关系，对所述训练集和提取的时序数据特征进行循环神经网络训练；

通过循环神经网络训练最大化似然对数以学习网络状态参数；

通过预测段初始时刻对应的似然函数参数关系和学习网络状态参数计算该时刻的时间序列预测容量；

基于初始时刻的时间序列预测容量计算下一时刻对应的似然函数参数关系和学习网络状态参数；

通过下一时刻对应的似然函数参数关系和学习网络状态参数计算下一时刻的时间序列预测容量；

迭代预测段的似然函数参数关系和学习网络状态参数以预测连续时间段的平常日时间序列预测容量；

根据预测段节假日前时间段的时序数据重新回归得到预测段的节假日效应；

将所述预测段的节假日效应与所述平常日时间序列预测容量结合得到最终预测结果。

9. 如权利要求1所述的时序数据容量预测方法，其特征在于，输出包括未来节假日效应的预测结果包括：

基于时序数据分解将所述训练集的时序数据分解为季节项、趋势项、节假日项和剩余项的加和；其中，所述季节项表示时序数据的周期性特征，趋势项表示时序数据的非周期性特征，节假日项表示节假日效应，即在当天是否存在节假日以及节假日产生的影响，季节项表示经典经验周期数据的周期性特征及其明显程度，趋势项对时序数据变点的同段内数据采用了时间相关的逻辑斯谛拟合。

10. 如权利要求1所述的时序数据容量预测方法，其特征在于，将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段包括：

通过差分曲线的异常值检测，判断时序数据水平突变的位置点；

根据所述位置点将时序数据分割为多个正常段并将多个连续的正常段划分为多个连续的特征段；

将多个正常段进行同一趋势的拼接；

将多个正常段按照“上升”、“平稳”、“下降”和类型、升降幅度、时间跨度分为多个连续的特征段。

11. 一种时序数据容量预测装置，包括：

预处理模块，对时序数据进行预处理；所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种；

周期性判断模块，提取时序数据的特征并判断所述时序数据是否具有周期性特征；

若所述时序数据具有周期性特征：

训练集确定模块,对预处理后的时序数据进行概念漂移检测确定训练集范围;

周期性模型建立模块,将所述训练集和提取的时序数据特征输入周期性预测模型,其中对历史节假日数据进行轮廓的回归保存以得到节假日效应;

警告模块,输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告;

若所述时序数据不具有周期性特征:

分割模块,将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;

预测模块,在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。

12. 一种电子设备,其特征在于,包括:

至少一个处理器;以及

与所述至少一个处理器耦合连接的存储器;其中,

所述存储器存储有计算机程序,所述计算机程序能够被所述至少一个处理器执行,以实现权利要求1-10任一项所述的方法。

13. 一种计算机可读存储介质,其特征在于,所述计算机可读存储介质用于存储计算机程序,当所述计算机程序被执行时,能够实现权利要求1-10任一项所述的方法。

时序数据容量预测方法、装置、电子设备及存储介质

技术领域

[0001] 本发明涉及计算机技术领域,更具体地说,涉及一种时序数据容量预测方法、装置、电子设备及存储介质。

背景技术

[0002] 随着计算机和互联网技术的发展,网上业务带来了极大的便利。业务系统中往往涉及多个业务指标(如交易量、磁盘容量、文件系统使用率、内存使用率、CPU使用率等),业务指标数据往往有一个安全的上界,保证指标数据在安全上界以下对于业务的正常稳定是非常重要的。随着业务的继续开展和增长,这类指标数据往往也会有逐渐增长乃至超过安全上界的可能,对于即将或者已经逼近安全上界的指标数据,管理员往往需要进行扩容、清理库等操作以保障系统的安全稳定。

现有技术通常采用基于告警阈值的处理方法,往往在指标数据到达阈值或者接近安全上界时才能够发现扩容、清理的需要,此方法不仅不能控制获得预警的时间,而且不能留给管理员足够的操作时间。

[0003] 传统的时序算法通常面临如下问题:数据整体平稳有周期性,但是在某个地方越来越高,传统单一预测算法无法处理该种特征;训练数据内存在异常值,影响预测模型的学习和后续预测;训练数据内存在节假日,传统算法无法预测或者处理不够合理;指标数据近一段时间内发生了明显的模式变化(如概念漂移);在较高的准确度要求下,传统算法预测指标资源消耗过多,时间过长。

发明内容

[0004] 本发明的目的为解决上述问题,提出了一种时序数据容量预测方法,包括:

对时序数据进行预处理;所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种;通过鲁棒统计的异常值筛选和指标周期分布特征,对于超出合理范围的异常值进行了筛选标识、剔除和空缺位置插值补充。对于不应该纳入预测的曲线特征段,算法会自动进行一定的推测,并将其从训练集中剔除。

[0005] 提取时序数据的特征并判断所述时序数据是否具有周期性特征;

若所述时序数据具有周期性特征:

对预处理后的时序数据进行概念漂移检测确定训练集范围;

将所述训练集和提取的时序数据特征输入周期性预测模型,其中对历史节假日数据进行轮廓的回归保存以得到节假日效应;

输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告;

若所述时序数据不具有周期性特征:

将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;

在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。

[0006] 优选的,采用k倍标准差阈值算法对异常点进行剔除,其中所述标准差为归一化中位数绝对偏差。

[0007] 优选的,若时序数据缺失段长度超出设定长度,则不对此段时序数据进行修复;若时序数据缺失段长度未超出设定长度,采用线性插值的方法对此段时序数据进行修复,同时完成时间戳调整。

[0008] 优选的,所述时序数据的特征至少包括周期性、数据粒度、数据容量变化类型、数据变化上下界、数据时间范围、节假日数据和非节假日数据中的一种。

[0009] 优选的,判断所述时序数据是否具有周期性特征包括:

对于节假日数据,使用其前或后自然时间段对应位置数据代替;

预设半自然时间段与自然时间段的偏移情况,分别计算对应的自相关系数,其中剔除半自然时间段和自然时间段自相关系数最差的时间;

若自然时间段自相关系数高于参考阈值,则判断时序数据存在周期性,所述参考阈值高于半自然时间段自相关系数的3倍。

[0010] 优选的,对预处理后的时序数据进行概念漂移检测确定训练集范围包括:

基于最后多个自然时间段内最后多个时间范围的平均异常程度、异常时间槽比例和时间戳补正计算异常分数;

判断所述异常分数最大处异常时间槽比例是否超出阈值,若超出,则判断发生概念漂移,以此多个自然时间段后的时序数据作为训练集。

[0011] 将一定时间之前的数据特征进行学习和预测,并将结果与近期真实数据进行比对,对连续重复发生特征的稳定区别的情况通过平均异常程度、异常事件槽比例和时间戳补正三个维度进行打分评估异常变化情况,根据异常打分结果判断是否发生了数据模式的变化。如果发生了数据模式的变化,则给出数据模式变化的起始时间,并使用变化后的最新数据进行指标训练和预测。

[0012] 优选的,对历史节假日数据进行轮廓的回归保存以得到未来节假日效应包括:

提取历史节假日前时间段的高百分位数和低百分位数;

将历史节假日分类为节假日值数据和节假日残差数据;

基于所述分类对历史节假日前时间段的起点到历史节假日后相同时间段的终点的时序数据进行轮廓的回归保存。

[0013] 优选的,输出包括节假日效应的预测结果包括:

对于平常日数据,根据所述训练集的统计分布特征确定似然函数参数关系;

基于似然函数参数关系,对所述训练集和提取的时序数据特征进行循环神经网络训练;

通过循环神经网络训练最大化似然对数以学习网络状态参数;

通过预测段初始时刻对应的似然函数参数关系和学习网络状态参数计算该时刻的时间序列预测容量;

基于初始时刻的时间序列预测容量计算下一时刻对应的似然函数参数关系和学习网络状态参数;

通过下一时刻对应的似然函数参数关系和学习网络状态参数计算下一时刻的时间序列预测容量；

迭代预测段的似然函数参数关系和学习网络状态参数以预测连续时间段的平常日时间序列预测容量；

根据预测段节假日前时间段的时序数据重新回归得到预测段的节假日效应；

将所述预测段的节假日效应与所述平常日时间序列预测容量结合得到最终预测结果。

[0014] 本发明对数据指标的节假日类别进行划分,记录不同节假日的节假日效应真实值曲线或者残差曲线,将其根据平常日水平的未来变化进行换算得到未来的节假日预测。

[0015] 优选的,输出包括未来节假日效应的预测结果包括:

基于时序数据分解将所述训练集的时序数据分解为季节项、趋势项、节假日项和剩余项的加和;其中,所述季节项表示时序数据的周期性特征,趋势项表示时序数据的非周期性特征,节假日项表示节假日效应,即在当天是否存在节假日以及节假日产生的影响,季节项表示经典经验周期数据的周期性特征及其明显程度,趋势项对时序数据变点的同段内数据采用了时间相关的逻辑斯谛拟合。

[0016] 优选的,将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段包括:

通过差分曲线的异常值检测,判断时序数据水平突变的位置点;

根据所述位置点将时序数据分割为多个正常段并将多个连续的正常段划分为多个连续的特征段;

将多个正常段进行同一趋势的拼接;

将多个正常段按照“上升”、“平稳”、“下降”和类型、升降幅度、时间跨度分为多个连续的特征段。

[0017] 基于同样的发明构思,本发明另提供一种时序数据容量预测装置,包括:

预处理模块,对时序数据进行预处理;所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种;

周期性判断模块,提取时序数据的特征并判断所述时序数据是否具有周期性特征;

若所述时序数据具有周期性特征:

训练集确定模块,对预处理后的时序数据进行概念漂移检测确定训练集范围;

周期性模型建立模块,将所述训练集和提取的时序数据特征输入周期性预测模型,其中对历史节假日数据进行轮廓的回归保存以得到节假日效应;

警告模块,输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告。

[0018] 若所述时序数据不具有周期性特征:

分割模块,将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;

预测模块,在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。

[0019] 本发明还提供一种电子设备,包括:

至少一个处理器;以及

与所述至少一个处理器耦合连接的存储器;其中,

所述存储器存储有计算机程序,所述计算机程序能够被所述至少一个处理器执行,以实现上述任一方法。

[0020] 本发明的另一方面在于,提供一种计算机可读存储介质,所述计算机可读存储介质用于存储计算机程序,当所述计算机程序被执行时,能够实现上述任一方法。

[0021] 有益效果:

本发明能够自动判断时序数据的类型,根据不同类型的时序采用不同的模型,并且能够有相对较快的运行速度。本发明方法较为灵活,对于周期型数据采用多种模型的结合,重点关注指标高值部分变化情况,结合周期特征对未来指标进行预测;对于非周期趋势型数据,算法通过将指标进行段分割和相似匹配找到曲线内在的变化相似段,以此作为预测的依据。

[0022] 本方法运行速度较快,消耗资源少,对于3个月长度的分钟级数据,算法在16G内存8核CPU计算机上学习预测的时间消耗为秒级,在保障准确率的前提下相比于传统算法大大减少了计算资源消耗。

[0023] 针对“指标何时会超出规划容量”这个问题,需要对指标的变化规律进行学习,对指标在未来增长的模式进行提取并给出未来一定时间的预测,并结合阈值设定方法,提前捕捉到指标在未来有增长并突破设定阈值的可能以及确定突破的大致时间,以辅助管理员进行提前的计划性的扩容、清理、资源分配等操作。

附图说明

[0024] 图1是本发明实施例1中时序数据容量预测方法的流程图;

图2是本发明实施例1中时序数据容量预测方法S2的流程图;

图3是本发明实施例1中时序数据容量预测方法S3的流程图;

图4是本发明实施例1中时序数据容量预测方法S4的流程图;

图5是本发明实施例1中时序数据容量预测方法S5的流程图;

图6是本发明实施例1中时序数据容量预测方法S6的流程图;

图7是本发明实施例1中时序数据容量预测装置示意图;

图8是本发明实施例2中时序数据容量预测方法中周期性预测模型基于循环神经网络的训练模型示意图;

图9是本发明实施例2中时序数据容量预测方法中周期性预测模型基于循环神经网络的预测模型示意图;

图10是本发明实施例2中时序数据容量预测方法中将多个正常段进行同一趋势的拼接示意图。

具体实施方式

[0025] 下面将参照附图更详细地描述本发明的具体实施例。虽然附图中显示了本发明的具体实施例,然而应当理解,可以以各种形式实现本发明而不应被这里阐述的实施例所限制。相反,提供这些实施例是为了能够更透彻地理解本发明,并且能够将本发明的范围完整的传达给本领域的技术人员。

[0026] 实施例1本实施例提供一种时序数据容量预测方法,如图1所示,该方法包括:

S1对时序数据进行预处理;所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种;采用k倍标准差阈值算法对异常点进行剔除,其中所述标准差为归一化中位数绝对偏差。若时序数据缺失段长度超出设定长度,则不对此段时序数据进行修复;若时序数据缺失段长度未超出设定长度,采用线性插值的方法对此段时序数据进行修复,同时完成时间戳调整。

[0027] S2提取时序数据的特征并判断所述时序数据是否具有周期性特征;所述时序数据的特征至少包括周期性、数据粒度、数据容量变化类型、数据变化上下界、数据时间范围、节假日数据和非节假日数据中的一种。

[0028] 若所述时序数据具有周期性特征:

S3对预处理后的时序数据进行概念漂移检测确定训练集范围;

S4将所述训练集和提取的时序数据特征输入周期性预测模型,其中对历史节假日数据进行轮廓的回归保存以得到节假日效应;

S5输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告;

若所述时序数据不具有周期性特征:

S6将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;

S7在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。

[0029] 如图2所示,S2中判断所述时序数据是否具有周期性特征包括:

S201对于节假日数据,使用其前或后自然时间段对应位置数据代替;

S202预设半自然时间段与自然时间段的偏移情况,分别计算对应的自相关系数,其中剔除半自然时间段和自然时间段自相关系数最差的时间;

S203若自然时间段自相关系数高于参考阈值,则判断时序数据存在周期性,所述参考阈值高于半自然时间段自相关系数的3倍。

[0030] 如图3所示,S3中对预处理后的时序数据进行概念漂移检测确定训练集范围包括:

S301基于最后多个自然时间段内最后多个时间范围的平均异常程度、异常时间槽比例和时间戳补正计算异常分数;

S302判断所述异常分数最大处异常时间槽比例是否超出阈值,若超出,则判断发生概念漂移,以此多个自然时间段后的时序数据作为训练集。

[0031] 如图4所示,S4中对历史节假日数据进行轮廓的回归保存以得到未来节假日效应包括:

S401提取历史节假日前时间段的高百分位数和低百分位数;

S402将历史节假日分类为节假日值数据和节假日残差数据;

S403基于所述分类对历史节假日前时间段的起点到历史节假日后相同时间段的终点的时序数据进行轮廓的回归保存。

[0032] 如图5所示,S5中输出包括节假日效应的预测结果包括:

S501对于平常日数据,根据所述训练集的统计分布特征确定似然函数参数关系;

S502基于似然函数参数关系,对所述训练集和提取的时序数据特征进行循环神经网络训练;

S503通过循环神经网络训练最大化似然对数以学习网络状态参数;

S504通过预测段初始时刻对应的似然函数参数关系和学习网络状态参数计算该时刻的时间序列预测容量;

S505基于初始时刻的时间序列预测容量计算下一时刻对应的似然函数参数关系和学习网络状态参数;

S506通过下一时刻对应的似然函数参数关系和学习网络状态参数计算下一时刻的时间序列预测容量;

S507迭代预测段的似然函数参数关系和学习网络状态参数以预测连续时间段的平常日时间序列预测容量;

S508根据预测段节假日前时间段的时序数据重新回归得到预测段的节假日效应;

S509将所述预测段的节假日效应与所述平常日时间序列预测容量结合得到最终预测结果。

[0033] 在优选的实施例中,输出包括未来节假日效应的预测结果包括:

基于时序数据分解将所述训练集的时序数据分解为季节项、趋势项、节假日项和剩余项的加和;其中,所述季节项表示时序数据的周期性特征,趋势项表示时序数据的非周期性特征,节假日项表示节假日效应,即在当天是否存在节假日以及节假日产生的影响,季节项表示经典经验周期数据的周期性特征及其明显程度,趋势项对时序数据变点的同段内数据采用了时间相关的逻辑斯谛拟合。在一些简单直观数据(无特殊概念漂移,形态变化不大的时序数据)的季节项和趋势项上,参考了简化的STL时序分解算法(Seasonal and Trend decomposition using Loess),以简化对该部分项的计算。

[0034] 本发明通过提取周期性的差分特征(周期性模型中未提到差分特征,补充说明),对指标其他周期的相同相近位置指标数据进行了对比确认,对于置信分数较高的特征部位,给与了单独的预测权重与子回归模型,使得这种特征能被学习并反映到未来预测中。

[0035] 如图6所示,S6中将预处理后的时序数据分割为多个连续的正常段包括:

S601通过差分曲线的异常值检测,判断时序数据水平突变的位置点;

S602根据所述位置点将时序数据分割为多个正常段并将多个连续的正常段划分为多个连续的特征段;

S603将多个正常段进行同一趋势的拼接;

S604将多个正常段按照“上升”、“平稳”、“下降”和类型、升降幅度、时间跨度分为多个连续的特征段。

[0036] 在优选的实施例中,另提供一种时序数据容量预测装置,如图7所示,包括:

预处理模块10,对时序数据进行预处理;所述预处理至少包括异常点剔除、指标缺失段长度判断与指标缺失段修复其中的一种;

周期性判断模块20,提取时序数据的特征并判断所述时序数据是否具有周期性特征;

若所述时序数据具有周期性特征:

训练集确定模块30,对预处理后的时序数据进行概念漂移检测确定训练集范围;

周期性模型建立模块40,将所述训练集和提取的时序数据特征输入周期性预测模型,

其中对历史节假日数据进行轮廓的回归保存以得到节假日效应；

警告模块50,输出包括未来节假日效应的预测结果,并与时序数据容量阈值进行比较,若超过所述时序数据阈值则产生警告。

[0037] 若所述时序数据不具有周期性特征:

分割模块60,将预处理后的时序数据分割为多个连续的正常段并将多个连续的正常段划分为多个连续的特征段;

预测模块70,在多个连续的特征段中找到与最尾部的若干个连续的特征段特征匹配的另外若干个连续段,以此另外若干个连续段对时序数据容量进行预测。

[0038] 本实施例能够在较低的资源消耗下,也能够保障预测合理地情况下完成预测任务,对于在16G内存8核CPU计算机上学习预测的时间消耗为秒级。而一些传统机器学习算法在同样条件下往往需要分钟级的时间消耗。

[0039] 在优选的实施例中,还提供一种电子设备,包括:

至少一个处理器;以及

与所述至少一个处理器耦合连接的存储器;其中,

所述存储器存储有计算机程序,所述计算机程序能够被所述至少一个处理器执行,以实现上述任一方法。

[0040] 在优选的实施例中,提供一种计算机可读存储介质,所述计算机可读存储介质用于存储计算机程序,当所述计算机程序被执行时,能够实现上述任一方法。

[0041] 实施例2 本实施例提供另一种时序数据容量预测方法,训练预测任务开启后,对一条KPI曲线首先执行特性描述(指标画像)和预处理,主要提取指标(即时序数据)的一些特征信息,包括:指标周期性、指标粒度、指标趋势变化类型、指标变化上下界、指标时间范围、指标内节假日情况等。

[0042] 其中,指标周期性提取部分主要是根据自相关系数(auto correlation)判断周期,算法中首先对于节假日数据执行替换,使用其前或后一周对应位置数据代替,然后预设半自然周与自然周的偏移情况,分别计算对应的自相关系数(在计算自相关系数过程中,分别忽略其中自相关系数最差的3天和7天),若周自相关系数高于一定参考阈值(该阈值由算法实验给出经验参考阈值)且比半周自相关系数高较多(3倍以上),则判断指标存在周周期。

[0043] 数据预处理部分,主要对于指标进行了指标内异常点剔除的操作和指标缺失段判断与修复。异常点剔除采用了k-sigma(k倍标准差阈值)的算法,并用鲁棒统计学中的MADN值(normalized median absolute deviation about the median, 归一化中位数绝对偏差)代替sigma标准差以减少异常值影响。指标缺失时对于指标缺失段长度进行判断,如果超出设定长度(默认12小时),则不对这部分指标进行修复;否则采用线性插值的方法进行修复,同时在该步骤中完成时间戳规整。

[0044] 之后,根据时间序列的类别和具体特征,进行了数据信息的整合并区分数据的实际情况,使用了合理算法模型进行特征的进一步提取、学习和预测,涉及的算法主要包括:DeepAR、Prophet、STL时序分解、鲁棒统计理论、线性提升树和回归模型、特征段匹配算法,针对周期型数据,算法首先对数据进行概念漂移(concept-drift)检测,确定训练集范围。这里采用对周期数据偏离其周期轮廓的持续性和稳定性,判断其是否已经连续偏离合理位

置,然后依次判断最后N周的后m天的异常分数($m=3,4,\dots,7N$),如果异常分数最大处异常时间槽(timeslot)比例超出阈值(占比50%以上),则认为该处发生了concept-drift,在数据充足时,尽量仅以此后的数据作为训练集。异常分数的计算方法主要是由3部分组成,分别为“平均异常程度”、“异常时间槽比例”、“时间戳补正”。其中第三部分时间戳补正是为了使尽可能早的位置被识别为概念漂移的起点。根据概念漂移检测的结果,决定其数据指标训练集的选择。

[0045] 算法根据历史节假日进行学习,对于长度为N天的节假日数据,根据其节前N天到节前3N天的数据水平进行提取(提取其高百分位数和低百分位数),并对节假日节前N天到节后N天的数据进行轮廓的回归保存(回归的指标根据设定是否为长节假日,分别为节假日值和节假日残差数据)。当产生未来平常日预测后,将根据未来预测中其节前N天到节前3N天的数据水平重新回归得到在未来的节假日效应并结合入预测最终结果中。

[0046] 在有足够计算资源与足够的历史数据的情况下,会选择DeepAR算法进行平常日的学习预测。其算法模型的主要示意图8和图9,图8为训练模型示意图,图9为预测模型示意图。其中 $\mathbf{Z}_{i,t}$ 表示时间序列i在t时刻的时间序列取值, $\mathbf{x}_{i,t}$ 表示时间序列i的在t时刻的提取特征。DeepAR将整个预测模型表达为一个如图9所示的循环神经网络(Recurrent Neural Network),图中 $\mathbf{h}_{i,t}$ 为网络参数。DeepAR基于 $\mathbf{Z}_{i,t}$ 的似然函数 $l(\mathbf{z}_{i,t}|\theta_{i,t})$ 给出预测曲线的概率分布,而似然函数 $l(\mathbf{z}_{i,t}|\theta_{i,t})$ 需要根据指标的统计分布特征确定。

[0047] 训练阶段,根据特征 $\mathbf{x}_{i,t}$ 与上一时刻的取值 $\mathbf{Z}_{i,t-1}$ 以及网络状态参数 $\mathbf{h}_{i,t-1}$ 确定当前t时刻的状态 $\mathbf{h}_{i,t}$,然后由实际取值 $\mathbf{Z}_{i,t}$ 以及预先根据数据分布设定的似然函数参数关系 $\theta(\mathbf{h}_{i,t})$,得到似然 $l(\mathbf{z}_{i,t}|\theta(\mathbf{h}_{i,t}))$ 。训练时即需要最大化似然对数和 $\sum_i \sum_t \log(l(\mathbf{z}_{i,t}|\theta(\mathbf{h}_{i,t})))$ 以学习网络参数。

[0048] 预测阶段,从最初段开始,计算得到预测段中第一个时间点对应的 $\mathbf{h}_{i,t}$ 与 $\theta(\mathbf{h}_{i,t})$ 计算,并根据分布 $\theta(\mathbf{h}_{i,t})$ 采样得到该时刻的时间序列预测值(带波浪上划线代表是采样得到的预测点),然后将其预测点结果迭代输入,重复以上方法得到下一个时刻点对应的 $\mathbf{h}_{i,t}$ 与 $\theta(\mathbf{h}_{i,t})$,并且由此采样得到下一时刻数据的取值分布情况,不断迭代重复根据新的分布特征给出下一时刻预测,从而完成对于一段连续时长数据的预测。

[0049] 在有充足的计算资源,且数据比较连续,有明显的周期和趋势特征时使用prophet算法。算法的主要思想是时序数据分解(Decomposition of Time Series),prophet将数据指标 $\mathbf{y}(t)$ 分解为季节项 $\mathbf{s}(t)$ 、趋势项 $\mathbf{g}(t)$ 、节假日项 $\mathbf{h}(t)$ 、剩余项 ϵ_t 的加和,也即

$$\mathbf{y}(t) = \mathbf{s}(t) + \mathbf{g}(t) + \mathbf{h}(t) + \epsilon_t$$

其中,季节项表示以周或者年为单位的周期特征,趋势项表示时间序列非周期性的持续变化趋势,节假日项表示在当天是否存在节假日以及节假日产生的影响。对于季节项,

prophet算法采用傅里叶级数提取并表达经典经验周期(周/年)数据指标的周期特征及其明显程度;对于趋势项,prophet算法采用了结合时间序列变点(change point)检测的方法,对变点之间的同段内数据采用了时间相关的逻辑斯谛拟合。在一些简单直观数据(无特殊concept-drift,形态变化不大的指标)的季节项和趋势项上,farseer参考了简化的STL时序分解算法(Seasonal and Trend decomposition using Loess),以简化对该部分项的计算。

[0050] 对于非周期数据,算法主要采用特征段匹配的方法进行预测。算法首先将数据中的水平突变(level-shift)检测出来,这里使用了差分曲线的异常值检测(应用k-sigma的离群点检测),判断发生level-shift的位置,然后根据此结果将指标分割为正常段,并将各个正常段在保证趋势正常的情况下进行拼接,拼接方式如图10所示。

[0051] 非周期数据预处理后进行学习和预测。根据指标数据段内的变化情况,将数据按照“上升”、“平稳”、“下降”分割为若干个段(segment),每个段记录其类型、升降幅度、时间跨度。尝试在训练曲线中找到与最尾部的若干个连续段足够相似的若干个连续段,以此为依据进行未来数据的预测。

[0052] 本领域普通技术人员可以意识到,结合本文中所公开的实施例描述的各示例的模块及算法步骤,能够以电子硬件、或者计算机软件和电子硬件的结合来实现。这些功能究竟以硬件还是软件方式来执行,取决于技术方案的特定应用和设计约束条件。专业技术人员可以对每个特定的应用来使用不同方法来实现所描述的功能,但是这种实现不应认为超出本发明的范围。

[0053] 所属领域的技术人员可以清楚地了解到,为描述的方便和简洁,上述描述的装置和设备的具体工作过程,可以参考前述方法实施例中的对应过程,在此不再赘述。

[0054] 在本申请所提供的实施例中,应该理解到,所揭露的装置和方法,可以通过其它的方式实现。例如,以上所描述的装置实施例仅仅是示意性的,例如,所述模块的划分,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式,例如多个模块或组件可以结合或者可以集成到另一个系统,或一些特征可以忽略,或不执行。另一点,所显示或讨论的相互之间的耦合或直接耦合或通信连接可以是通过一些接口,装置或模块的间接耦合或通信连接,可以是电性,机械或其它的形式。

[0055] 所述作为分离部件说明的模块可以是或者也可以不是物理上分开的,作为模块显示的部件可以是或者也可以不是物理模块,即可以位于一个地方,或者也可以分布到多个网络模块上。可以根据实际的需要选择其中的部分或者全部模块来实现本发明实施例方案的目的。

[0056] 另外,在本发明各个实施例中的各功能模块可以集成在一个处理模块中,也可以是各个模块单独物理存在,也可以两个或两个以上模块集成在一个模块中。

[0057] 所述功能如果以软件功能模块的形式实现并作为独立的产品销售或使用,可以存储在一个计算机可读取存储介质中。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行本发明各个实施例节能信号发送/接收的方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、ROM、RAM、磁碟或者光盘等各种可

以存储程序代码的介质。

[0058] 以上描述仅为本申请的较佳实施例以及对所运用技术原理的说明。本领域技术人员应当理解,本申请中所涉及的发明范围,并不限于上述技术特征的特定组合而成的技术方案,同时也应涵盖在不脱离所述发明构思的情况下,由上述技术特征或其等同特征进行任意组合而形成的其它技术方案。例如上述特征与本申请中公开的(但不限于)具有类似功能的技术特征进行互相替换而形成的技术方案。

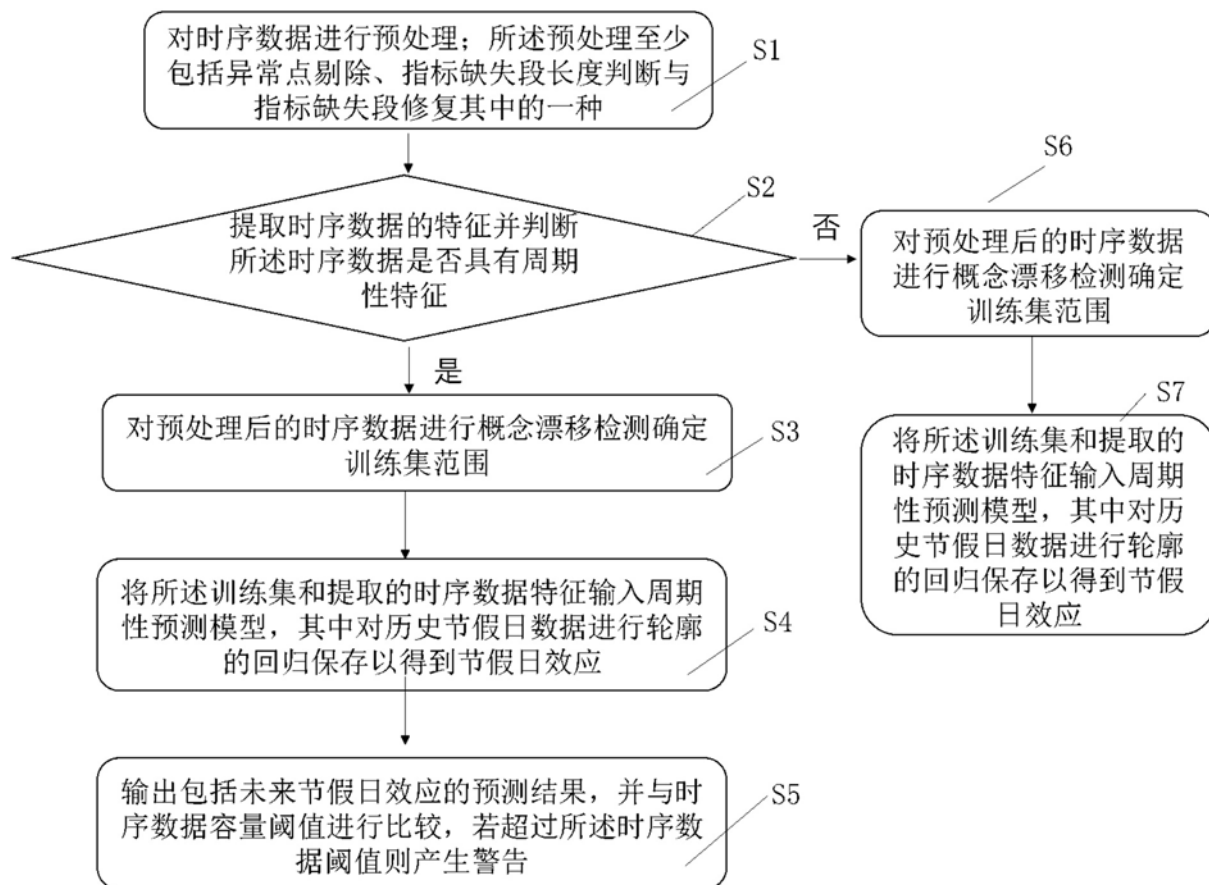


图1

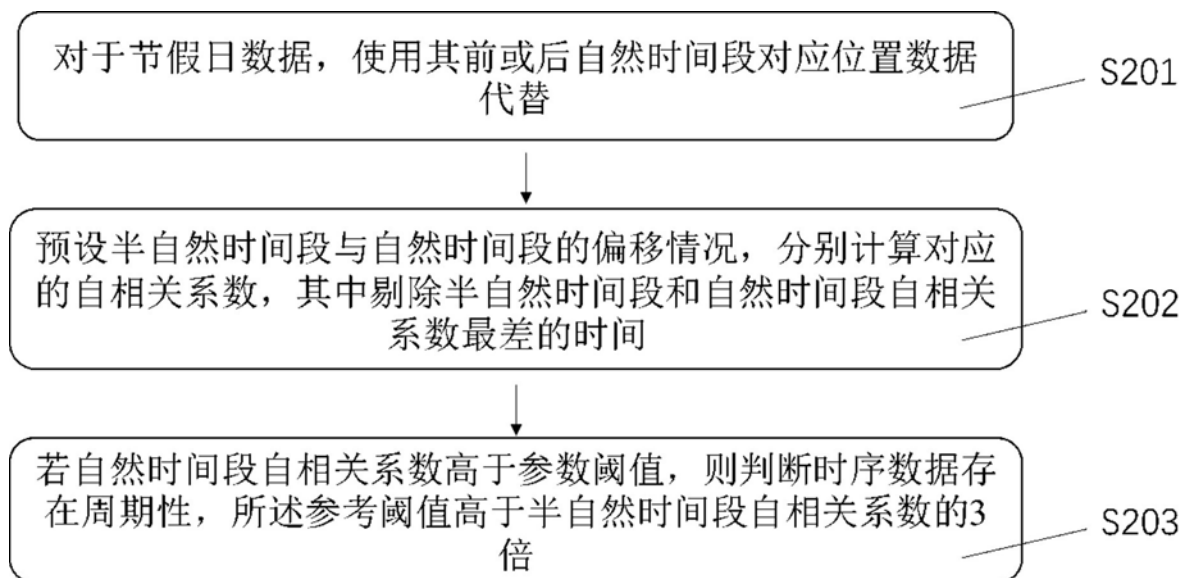


图2

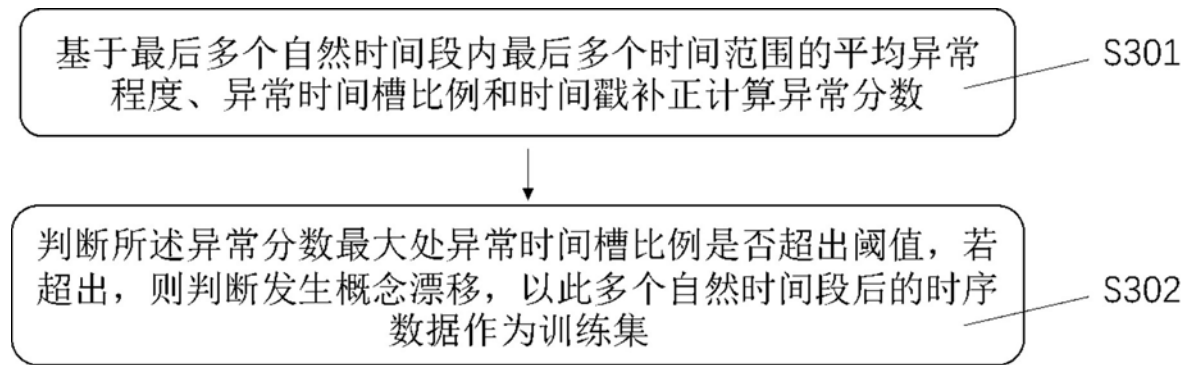


图3




图4



图5




图6




图7




图8




图9




图10