



(21) 申请号 202111127982.7

G06N 20/00 (2019.01)

(22) 申请日 2021.09.26

(56) 对比文件

(65) 同一申请的已公布的文献号

CN 105160181 A, 2015.12.16

申请公布号 CN 113900844 A

CN 110888755 A, 2020.03.17

(43) 申请公布日 2022.01.07

审查员 王健

(73) 专利权人 北京必示科技有限公司

地址 100083 北京市海淀区东升大厦B座
516室

(72) 发明人 沈梦家 曹立 隋楷心 刘大鹏

王继斌 张文池 吴楠 陈恒茂

(74) 专利代理机构 北京中知法苑知识产权代理

有限公司 11226

专利代理师 陈俊由

(51) Int. Cl.

G06F 11/07 (2006.01)


权利要求书3页 说明书9页 附图3页

(54) 发明名称

一种基于服务码级别的故障根因定位方法、
系统及存储介质

(57) 摘要

本发明提供一种基于服务码级别的故障根因定位方法、系统及存储介质,方法包括以下步骤:构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;构建基于多维指标的时间序列异常检测模型,对全局异质拓扑图的每条调用边进行异常检测;基于每条调用边的异常检测结果,生成异质故障图;基于随机游走的对象级别排序算法,对获得的异质故障图进行故障根因定位。本发明通过采用异质拓扑图,简洁清晰的展示更细粒度的服务码调用关系和隶属关系;通过融合多维指标的关联特征,有效提高了异质拓扑结构中调用边的指标异常检测的正确率;通过异质图的节点排序算法,有效提高了故障根因定位的准确性。



1.一种基于服务码级别的故障根因定位方法,其特征在于,包括以下步骤:
 S1构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;
 S2构建基于多维指标的时间序列异常检测模型,对所述全局异质拓扑图的每条调用边进行异常检测;
 S3基于每条所述调用边的异常检测结果,生成异质故障图;
 S4基于随机游走的对象级别排序算法,对获得的所述异质故障图进行故障根因定位;
 所述S2还包括以下步骤:
 S2.1对n指标对应的时间窗口的时间序列进行归一化;
 S2.2通过图注意力机制学习节点的融合特征;
 S2.3基于获得的所有节点的融合特征 h_i ,学习获得不同指标对应的时间序列的嵌入特征;
 S2.4基于获得的不同指标对应的时间序列的嵌入特征,得到所有指标的时间序列在t时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

S2.5基于得到的所有指标的时间序列在t时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$,计算获得代表指标的偏离程度的异常分数值 $score_i(t)$;

S2.6基于获得的异常分数值 $score_i(t)$,判断调用边是否异常。

2.一种如权利要求1所述的基于服务码级别的故障根因定位方法,其特征在于,所述全局异质拓扑图的每条所述调用边是由交易明细数据和设定的时间粒度聚合生成的时间序列指标数据,所述指标数据至少包括交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间中的两种或多种的组合。

3.一种如权利要求1所述的基于服务码级别的故障根因定位方法,其特征在于,所述S2.2通过图注意力机制学习节点的融合特征包括:

节点i的融合特征 h_i 通过如下公式计算:

$$h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} v_j \right)$$

其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示sigmoid激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重,节点 v_j 表示第j个KPI指标对应的w维特征向量;关联权重 α_{ij} 通过以下公式计算:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})};$$

其中, $e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$, i, j 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{i1} 表示节点 v_i 和节点 v_1 之间的调用边的注意力值, $\oplus$ 表示特征连接操作,LeakyReLU为激活函数,W表示可学习的参数矩阵,L表示 v_j 节点的邻居节点数量,i表示 v_i 节点的邻居节点的序号。

4.一种如权利要求1所述的基于服务码级别的故障根因定位方法,其特征在于,所述S4包括以下步骤:

S4.1基于S3生成的异质故障图,确定对象集合V和对象类型集合A;

S4.2基于获得的对象类型集合A,为不同对象类型分配相应的异常传播因子;

S4.3基于获得的对象集合V,采用PageRank算法迭代计算得到各个对象的枢纽值作为各个对象的初始根因分数 R_{ex} ;

S4.4基于获得的异常传播因子和初始根因分数,确定每个对象的根因分数 R_x ;S4.5基于获得的每个对象的根因分数,选择top-K的根因分数对应的对象作为故障根因定位结果。

5.一种如权利要求4所述的基于服务码级别的故障根因定位方法,其特征在于,所述S4.2包括:所述异常传播因子通过专家知识进行分配或者基于历史数据通过组合搜索优化算法进行分配。

6.一种如权利要求4所述的基于服务码级别的故障根因定位方法,其特征在于,所述S4.4包括:

对象x的根因分数 R_x 通过以下公式计算:

$$R_x = \varepsilon R_{ex} + (1 - \varepsilon) \sum_{y \in Y} \gamma_{xy} M_{xy}^T R_y;$$

其中,X、Y分别表示对象类型集合A中类型为X的对象集合和类型为Y的对象集合,x表示类型为X的对象集合中的对象,y表示类型为Y的对象集合中的对象; R_x 和 R_y 分别表示对象x和对象y的根因分数, R_{ex} 为x节点的初始根因分数; M_{xy} 为邻接矩阵, M_{xy} 中的元素用 m_{xy} 表示,如果对象x与对象类型Y之间存在关系,则 $m_{xy} = \text{Num}(x, Y)$;如果对象x与对象类型Y之间不存在关系,则 $m_{xy} = 0$; $\text{Num}(x, Y)$ 表示对象x与类型为Y的对象集合中所有对象之间的关系数量的总和; γ_{xy} 表示对象类型X与对象类型Y之间的异常传播因子, $\sum_{y \in Y} \gamma_{xy} = 1$, ε 表示衰减因子。

7.一种如权利要求4所述的基于服务码级别的故障根因定位方法,其特征在于,所述top-K的根因分数表示前K个最大的根因分数;所述S4.5还包括:将获得的所述故障根因定位结果以可视化形式显示。

8.一种基于服务码级别的故障根因定位系统,其特征在于,系统主要包括以下模块:

全局异质拓扑图生成模块,用于构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;

异常检测模块,用于构建基于多维指标的时间序列异常检测模型,对所述全局异质拓扑图的每条调用边进行异常检测;

异质故障图生成模块,用于基于每条所述调用边的异常检测结果,生成异质故障图;

故障根因定位模块,用于基于随机游走的对象级别排序算法,对获得的所述异质故障图进行故障根因定位;

所述构建基于多维指标的时间序列异常检测模型,对所述全局异质拓扑图的每条调用边进行异常检测还包括以下步骤:

S2.1对n指标对应的时间窗口的时间序列进行归一化;

S2.2通过图注意力机制学习节点的融合特征;

S2.3基于获得的所有节点的融合特征 H_i ,学习获得不同指标对应的时间序列的嵌入特征;

S2.4基于获得的不同指标对应的时间序列的嵌入特征,得到所有指标的时间序列在t时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

S2.5基于得到的所有指标的时间序列在t时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$,计算获得代表指标的偏离程度的异常分数值scorei(t);

S2.6基于获得的异常分数值scorei(t),判断调用边是否异常。

9.一种存储介质,其特征在于,其存储有计算机程序;当所述计算机程序被计算机设备中的处理器执行时,计算机设备执行如权利要求1-7任一项所述的方法。

一种基于服务码级别的故障根因定位方法、系统及存储介质

技术领域

[0001] 本发明涉及故障根因定位,尤其涉及基于服务码级别的故障根因定位。

背景技术

[0002] 随着云计算、服务计算等技术的快速发展和社会生产对业务需求量的与日俱增,越来越多现代化企业将应用程序和系统服务部署在云计算环境中,称为分布式云应用程序或微服务。相比于传统集中式架构,分布式架构中具备更好的组件扩展性、更高的开发生产力和更低的成本。

[0003] 为了保证系统的高可用性和可靠性,应用程序提供商必须部署链路监控系统来采集每个服务的关键性能指标,例如网络响应时间、服务响应率和成功率等,以此来处理复杂的分布式环境以满足可用性限制和严格的服务级别目标。然而,随着业务需求日益复杂和微服务规模日益增大,在发生故障时,由于存在跨系统间的多重调用依赖关系,会产生大量的指标告警,此时系统管理员面对海量的告警指标信息,仅依赖人工分析难以迅速排查到关键告警指标及其对应的故障根因系统,因此需要利用机器学习算法自动处理和分析监控指标数据和系统拓扑关系,以此来迅速地定位到故障根源系统。

[0004] 然而,现有的链路追踪监控系统多数仅采集系统间调用关系数据,基于系统层面的调用关系进行故障根因定位,未考虑系统调用的服务码关键信息,因此,现有方案难以定位到细粒度的故障根源问题,且系统层级粗粒度的数据聚合信息容易导致异常信息被隐藏。

[0005] 另外,由于业务的复杂性和周期性,现有的基于固定阈值或者 k -sigma的简单异常检测策略会存在较多的误报或者漏报,例如告警规则“响应率低于90%且时间超过3分钟”在不同的业务中的效果将并不尽如人意,难以达到理想的效果。且目前大部分异常检测算法仅针对单一指标进行异常检测触发告警,未考虑多个关键性能指标间存在的复杂依赖关系,容易造成误报,尤其在异质拓扑结构中较细粒度的调用边的指标异常检测场景中,误报率较高。

[0006] 最后,针对结合系统和服务码后的数据场景,目前学术界和工业界多数采用同一级别的调用数据进行分析,但大部分实际场景中涉及多种不同级别的调用数据,情况往往更加复杂。因此,需要提出一种融合系统和服务码的故障根因定位方案。

发明内容

[0007] 为了解决现有技术中存在的上述问题,本发明提供:

[0008] 一种基于服务码级别的故障根因定位方法,主要包括以下步骤:

[0009] S1构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;

[0010] S2构建基于多维指标的时间序列异常检测模型,对全局异质拓扑图的每条调用边进行异常检测;

[0011] S3基于每条调用边的异常检测结果,生成异质故障图;

- [0012] S4基于随机游走的对象级别排序算法,对获得的异质故障图进行故障根因定位。
- [0013] 一种基于服务码级别的故障根因定位系统,主要包括以下模块:
- [0014] 全局异质拓扑图生成模块,用于构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;
- [0015] 异常检测模块,用于构建基于多维指标的时间序列异常检测模型,对全局异质拓扑图的每条调用边进行异常检测;
- [0016] 异质故障图生成模块,用于基于每条调用边的异常检测结果,生成异质故障图;
- [0017] 故障根因定位模块,用于基于随机游走的对象级别排序算法,对获得的异质故障图进行故障根因定位。
- [0018] 一种存储介质,其存储有计算机程序;当所述计算机程序被计算机设备中的处理器执行时,计算机设备执行如上述任一项所述的方法。
- [0019] 本发明通过构建异质拓扑图,简洁清晰的展示更细粒度的服务码调用关系和隶属关系;通过融合多维指标的关联特征,构建基于多维指标的时间序列异常检测模型,实现全局异质拓扑图的调用边的异常检测,相比于现有技术存在的仅针对单一指标进行异常检测导致的误报率高的技术问题,本发明有效提高了异质拓扑结构中调用边的指标异常检测的正确率;进一步通过异质图的节点排序算法,结合机器学习算法自动处理得到当前告警对应的异质故障图和根因系统,并以可视化图和根源推荐的形式简洁地展示给系统以用于后续分析和处理,能够辅助管理员高效地定位到故障根源,有效提高了故障根因定位的准确性。

附图说明

- [0020] 为了更清楚地说明发明实施例或现有技术中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是发明的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。
- [0021] 附图1本发明的方法流程图
- [0022] 附图2本发明的系统、服务码调用关系的异质拓扑图
- [0023] 附图3本发明的基于多维指标的时间序列异常检测模型
- [0024] 附图4本发明的指标异常检测结果示意图
- [0025] 附图5本发明的异质故障图
- [0026] 附图6本发明的故障根因定位可视化界面

具体实施方式

- [0027] 为了能够更清楚地理解本发明的上述目的、特征和优点,下面结合附图和具体实施方式对本发明进行进一步的详细描述。需要说明的是,在不冲突的情况下,本申请的实施例及实施例中的特征可以相互组合。
- [0028] 在下面的描述中阐述了很多具体细节以便于充分理解本发明,但是,本发明还可以采用其他不同于在此描述的方式来实施,因此,本发明的保护范围并不受下面公开的具体实施例的限制。

[0029] 实施例一

[0030] 为解决现有技术存在的问题,本实施例提供一种基于服务码级别的故障根因定位方法,其流程图如图1所示,主要包括以下步骤:

[0031] S1构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0032] 为了定位到更细粒度的服务码级别的异常和根因,本发明提出了服务码和应用系统间混合关系的构图策略。此外,如果是存在使用企业服务总线系统ESB_F5转发的系统调用,可以通过整理CMDB服务调用对照表来获取上下游系统中的服务码调用关系和服务码隶属关系。下面以实际样例数据来描述异质拓扑图的构建过程。

[0033] 业务监控系统在日志中详细采集业务交易的调用数据及其状态,例如某个告警时刻的调用日志解析后如下表1所示:

	时间	调用方	接收方	服务码	是否响应	是否成功	响应时间
[0034]	2021-05-10 10:00:01.133	S1	S4	T1	否	否	200ms
	2021-05-10 10:00:03.224	S2	S4	T1	否	否	300ms
	...	...	...	...	...	...	...
	2021-05-10 10:00:06.453	S3	S4	T2	是	是	10ms

[0035] 表1.解析后的交易明细数据

[0036] 可以看出此时数据中包含系统节点S1,S2,S3,S4及其调用的服务码节点T1,T2。全面考虑节点间存在的调用关系,构建得到的包括系统节点、服务码节点调用关系的异质拓扑图如图2所示,图2得到的是反应全局系统、服务码的调用关系图,其中每条调用边是由交易明细数据和设定的时间粒度聚合形成的时间序列指标数据,本发明采用的指标包括:交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间。相对于现有技术仅涉及系统间的调用拓扑图,本发明使用的包括系统和服务码间调用关系的异质拓扑图能够捕捉到更细粒度的服务码调用关系和隶属关系,表示形式简洁清晰。

[0037] 由于实际业务中业务量庞大且非常复杂,所以得到的全局异质拓扑图往往非常复杂。但在实际生产环境中发生故障时仅局部业务会受到影响,因此本发明提出对全局异质拓扑图进行调用边进行异常检测,以得到发生故障的局部异质拓扑图。

[0038] S2构建基于多维指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。其中,基于多维指标的时间序列异常检测模型如图3所示,通过图注意力机制构建。S2具体包括以下步骤:

[0039] S2.1对n个指标对应的时间窗口的时间序列进行归一化;

[0040] 其中,n表示每个调用边统计的KPI指标的个数,为考虑所有指标间的关联特征,将上述n个KPI指标转化为节点进行表示,即第i个指标对应节点 v_i 。采用min-max归一化方法,得到n个KPI指标对应的输入特征 $\{v_1, v_2, \dots, v_n\}$,其中 $v_i \in \mathbb{R}^w$,节点 v_i 表示第i个KPI指标对应的w维特征向量,特征向量的维度w与时间窗口的维度相对应。

[0041] S2.2通过图注意力机制学习节点的融合特征。

[0042] 节点 v_i 的融合特征 h_i 通过如下公式计算：

$$[0043] \quad h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} V_j \right)$$

[0044] 其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示sigmoid激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重,节点 V_j 表示第 j 个指标对应的 w 维特征向量,关联权重 α_{ij} 通过以下公式计算：

$$[0045] \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})}$$

[0046] 其中, $e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$, e_{ij} 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{i1} 表示节点 v_i 和节点 v_1 之间的调用边的注意力值, $\oplus$ 表示特征连接操作,LeakyReLU为激活函数, W 表示可学习的参数矩阵, L 表示 v_j 节点的邻居节点数量, l 表示 v_i 节点的邻居节点的序号。

[0047] 计算得到所有节点的融合特征,用 H_i 表示。

[0048] S2.3基于获得的所有节点的融合特征 H_i ,学习获得不同指标对应的时间序列的嵌入特征。

[0049] 经过图注意力机制学习后,所有节点的融合特征 H_i 的输出特征维度为 $n*w$,将其与原始序列特征相连得到 $n*2w$ 维特征,然后再输入到LSTM模块中编码长期时序依赖特征,学习获得不同指标对应的时间序列的嵌入特征。

[0050] S2.4基于获得的所述不同指标对应的时间序列的所述嵌入特征,得到所有指标的时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

[0051] 具体的,将所有所述指标的所述嵌入特征输入到多层感知机MLP中得到所有时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$,采用均方差损失函数MSE作为优化函数:

$$[0052] \quad L_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i^{(t)} - v_i^{(t)})^2}$$

[0053] 其中, n 表示预测的指标的个数。

[0054] S2.5基于得到的所有所述指标的时间序列在 t 时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$,计算获得代表指标偏离程度的异常分数值 $\text{score}_i(t)$ 。

[0055] 其中,对于第 i 个指标的偏离值通过以下公式计算:

$$[0056] \quad \text{err}_i^{(t)} = |\hat{v}_i^{(t)} - v_i^{(t)}|$$

[0057] 通过以下公式对指标的偏离值进行标准化:

$$[0058] \quad \text{score}_i(t) = \frac{\text{err}_i^{(t)} - \tilde{\mu}_i}{\tilde{\sigma}_i}$$

[0059] 其中, $\text{score}_i(t)$ 为异常分数值, $\tilde{\mu}$ 和 $\tilde{\sigma}$ 分别表示中位数和四分位数而不是均值和标准差, 实验证明, 上述归一化效果表现效果最优。通过采用基于多指标的时间序列异常检测模型, 本发明可以更加直观的观察每个指标的偏离程度。

[0060] S2.6 基于获得的所述异常分数值 $\text{score}_i(t)$, 判断所述调用边是否异常。具体的, 将获得的代表指标的偏离程度的所述异常分数值 $\text{score}_i(t)$ 与预设的阈值相比, 当所述异常分数值 $\text{score}_i(t)$ 大于所述阈值时, 判定所述调用边的检测结果为异常。检测结果如图4所示, 红色边表示异常, 黑色边表示正常。

[0061] 相比于传统的时间序列异常检测方法, 本发明构建的基于多维指标的时间序列异常检测模型不依赖于任何数据分布的假设, 而且考虑了业务调用的多维指标间的关联依赖特征, 使得异常检测更加准确和高效。

[0062] S3 基于每条调用边的异常检测结果, 生成异质故障图。

[0063] 具体的, 基于 S2 得到异质拓扑图中的异常调用边, 从全局异质拓扑图中过滤掉检测结果为正常的调用边数据, 得到仅显示发生故障部分的异质故障图。例如, 对图2的全局异质拓扑图过滤后得到如图5所示的异质故障图。

[0064] S4 基于随机游走的对象级别排序算法, 对获得的异质故障图进行故障根因定位。

[0065] 具体的, S4 包括以下步骤:

[0066] S4.1 基于 S3 生成的异质故障图, 确定对象集合 V 和对象类型集合 A 。

[0067] 具体的, S3 生成的异质故障图可形式化地表示为 $G = (V, E)$, 其中, v, e 分别表示对象集合和关系集合。由于异质图中包含多种类型的对象, 设置对象类型映射函数 $\phi: V \rightarrow A$, 其中 A 表示映射后不重复的对象类型集合, 通过映射函数将多种不同实例的同一类型的对象映射到相对应的对象类型。

[0068] S4.2 基于获得的对象类型集合 A , 为不同对象类型分配相应的异常传播因子。

[0069] 基于异质故障图中不同对象类型的重要程度, 为不同对象类型分配相应的异常传播因子。具体的, 可以通过专家知识进行分配或者基于历史数据通过组合搜索优化算法, 例如模拟退火优化算法, 来学习获得不同对象类型的异常传播因子。

[0070] 相比于现有技术未考虑不同对象类型之间的异常传播差异性的做法, 本申请通过设置不同对象类型之间的异常传播因子, 用于表达不同对象类型之间异常传播的权重的差异性, 有效提高了后续根因分数计算的准确性和针对性。

[0071] S4.3 基于获得的对象集合 V , 采用 PageRank 算法迭代计算得到各个对象的枢纽值作为各个对象的初始根因分数 R_{ea} 。

[0072] 其中, a 表示对象集合 V 中的任一对象。

[0073] S4.4 基于获得的异常传播因子和初始根因分数, 确定每个对象的根因分数 R_x 。

[0074] 具体的, 通过下式得到对象 x 的根因分数 R_x :

$$[0075] \quad R_x = \varepsilon R_{ex} + (1 - \varepsilon) \sum_{y \in V} \gamma_{xy} M_{xy}^T R_y$$

[0076] 其中, X, Y 分别表示对象类型集合 A 中类型为 X 的对象集合和类型为 Y 的对象集合, x 表示类型为 X 的对象集合中的对象, y 表示类型为 Y 的对象集合中的对象; R_x 和 R_y 分别表示对

象 x 和对象 y 的根因分数; M_{xy} 为邻接矩阵, M_{xy} 中的元素用 m_{xy} 表示,如果对象 x 与对象类型 Y 之间存在关系,则 $m_{xy} = \text{Num}(x, Y)$;如果对象 x 与对象类型 Y 之间不存在关系,则 $m_{xy} = 0$; $\text{Num}(x, Y)$ 表示对象 x 与类型为 Y 的对象集合中所有对象之间的关系数量的总和; γ_{xy} 表示对象类型 X 与对象类型 Y 之间的异常传播因子, $\sum_{\forall X} \gamma_{XY} = 1$, ε 表示衰减因子,根据专家知识进行选择。

[0077] 本发明通过结合异质图的对象排序算法,有效解决了初始根因分数未考虑到不同对象类型间关系的问题。

[0078] S4.5基于获得的每个对象的根因分数,选择top-K的根因分数对应的对象作为故障根因定位结果。

[0079] 其中,top-K的根因分数表示前K个最大的根因分数。

[0080] 具体的,将获得的故障根因定位结果以可视化形式显示,如图6所示,供系统管理员参考。

[0081] 本发明通过采用异质拓扑图,简洁清晰的展示了更细粒度的服务码调用关系和隶属关系;通过融合多维指标的关联特征,有效提高了异质拓扑结构中调用边的指标异常检测的正确率;通过采用异质图的节点排序算法进行根因定位,不仅考虑了异质图中对象异常传播的枢纽值,还考虑了不同对象类型间的异常传播因子,系统监控数据通过上述算法处理框架后,结合机器学习算法自动化处理得到当前告警对应的异质故障图和根因系统,并以可视化形式和根因推荐的形式简洁地展示给系统以进行分析和处理,能够辅助管理员高效地定位到故障根源,有效提高了故障根因定位的准确性。

[0082] 实施例二

[0083] 本实施例提供一种基于服务码级别的故障根因定位系统,主要包括以下模块:

[0084] 全局异质拓扑图生成模块,用于构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0085] 为了定位到更细粒度的服务码级别异常和根因,本发明提出了服务码和应用系统间混合关系的构图策略。此外,如果是存在使用企业服务总线系统ESB_F5转发的系统调用,可以通过整理CMDB服务调用对照表来获取上下游系统中的服务码调用关系和服务码隶属关系。

[0086] 异常检测模块,用于构建基于多维指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。其中,异常检测模型如图3所示,通过图注意力机制构建。异常检测模块用于实现以下功能:

[0087] 首先对 n 个指标对应的时间窗口的时间序列进行归一化。

[0088] 其中, n 表示每个调用边统计的KPI指标的个数,为考虑所有指标间的关联特征,将上述 n 个KPI指标转化为节点进行表示,即第 i 个指标对应节点 v_i 。采用min-max归一化方法,得到 n 个KPI指标对应的输入特征 $\{v_1, v_2, \dots, v_n\}$ 其中 $v_i \in \mathbb{R}^w$,节点 v_i 表示第 i 个KPI指标对应的 w 维特征向量,特征向量的维度 w 与时间窗口的维度相对应。

[0089] 通过图注意力机制学习不同节点的融合特征。

[0090] 具体的,节点 v_i 的融合特征 h_i 通过如下公式计算:

$$[0091] \quad h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} V_j \right)$$

[0092] 其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示 sigmoid 激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重, 节点 V_j 表示第 j 个指标对应的 w 维特征向量, 关联权重 α_{ij} 通过以下公式计算:

$$[0093] \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})}$$

$$[0094] \quad e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$$

[0095] 其中, e_{ij} 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{il} 表示节点 v_i 和节点 v_l 之间的调用边的注意力值, $\oplus$ 表示特征连接操作, LeakyReLU 为激活函数, W 表示可学习的参数矩阵, L 表示 v_j 节点的邻居节点数量, l 表示 v_i 节点的邻居节点的序号。计算得到所有节点的融合特征, 用 H_i 表示。

[0096] 基于获得的所有节点的融合特征 H_i , 学习获得不同指标对应的时间序列的嵌入特征。

[0097] 经过图注意力机制学习后, 所有节点的融合特征 H_i 的输出特征维度为 $n \times w$, 将其与原始序列特征相连得到 $n \times 2w$ 维特征, 然后再输入到 LSTM 模块中编码长期时序依赖特征, 学习获得不同指标对应的时间序列的嵌入特征。

[0098] 基于获得的所述不同指标对应的时间序列的所述嵌入特征, 得到所有指标的时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

[0099] 具体的, 将所有所述指标的所述嵌入特征输入到多层感知机 MLP 中得到所有时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$; 采用均方差损失函数 MSE 作为优化函数:

$$[0100] \quad L_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i^{(t)} - v_i^{(t)})^2}$$

[0101] 其中, n 表示预测的指标的个数。本发明采用基于多指标的时间序列异常检测模型, 可以更加直观地观察到每个指标的偏离程度。

[0102] 基于得到的所有所述指标的时间序列在 t 时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$, 计算获得代表指标偏离程度的异常分数值 $\text{score}_i(t)$ 。

[0103] 其中, 对于第 i 个指标的偏离值通过以下公式计算:

$$[0104] \quad \text{err}_i^{(t)} = |\hat{v}_i^{(t)} - v_i^{(t)}|$$

[0105] 通过以下公式对指标的偏离值进行标准化:

$$[0106] \quad \text{score}_i(t) = \frac{\text{err}_i^{(t)} - \tilde{\mu}_i}{\tilde{\sigma}_i}$$

[0107] 其中, $\text{score}_i(t)$ 为异常分数值, $\tilde{\mu}$ 和 $\tilde{\sigma}$ 分别表示中位数和四分位数而不是均值和标准差, 实验证明, 上述归一化效果表现效果最优。通过采用基于多指标的时间序列异常检测模型, 本发明可以更加直观的观察每个指标的偏离程度。

[0108] 基于获得的所述异常分数值 $\text{score}_i(t)$, 判断所述调用边是否异常。

[0109] 具体的, 将获得的代表指标的偏离程度的所述异常分数值 $\text{score}_i(t)$ 与预设的阈值相比, 当所述异常分数值 $\text{score}_i(t)$ 大于所述阈值时, 判定所述调用边的检测结果为异常。检测结果如图4所示, 红色边表示异常, 黑色边表示正常。

[0110] 相比于传统的时间序列异常检测方法, 本发明构建的基于多维指标的时间序列异常检测模型不依赖于任何数据分布的假设, 而且考虑了业务调用的多维指标间的关联依赖特征, 使得异常检测更加准确和高效。

[0111] 异质故障图生成模块, 用于基于每条调用边的异常检测结果, 生成异质故障图。

[0112] 具体的, 基于异常检测模块得到异质拓扑图中的异常调用边, 从全局异质拓扑图中过滤掉检测结果为正常的调用边数据, 得到仅显示发生故障部分的异质故障图。例如, 对图2的全局异质拓扑图过滤后得到如图5所示的异质故障图。

[0113] 故障根因定位模块, 用于基于随机游走的对象级别排序算法, 对获得的异质故障图进行故障根因定位。

[0114] 具体的, 故障根因定位模块用于实现以下功能:

[0115] 基于异质故障图生成模块生成的异质故障图, 确定对象集合 V 和对象类型集合 A 。

[0116] 具体的, 异质故障图生成模块生成的异质故障图可形式化地表示为 $\mathcal{G} = (V, \mathcal{E})$, 其中, $V, \mathcal{E}$ 分别表示对象集合和关系集合。由于异质图中包含多种类型的对象, 设置对象类型映射函数 $\phi: V \rightarrow A$, 其中 A 表示映射后不重复的对象类型集合, 通过映射函数将多种不同实例的同一类型的对象映射到相对应的对象类型。

[0117] 基于获得的对象类型集合 A , 为不同对象类型分配相应的异常传播因子。

[0118] 基于异质故障图中不同对象类型的重要程度, 为不同对象类型分配相应的异常传播因子。具体的, 可以通过专家知识进行分配或者基于历史数据通过组合搜索优化算法, 例如模拟退火优化算法, 来学习获得不同对象类型的异常传播因子。

[0119] 相比于现有技术未考虑不同对象类型之间的异常传播差异性的做法, 本申请通过设置不同对象类型之间的异常传播因子, 用于表达不同对象类型之间异常传播的权重的差异性, 有效提高了后续根因分数计算的准确性和针对性。

[0120] 基于获得的对象集合 V , 采用PageRank算法迭代计算得到各个对象的枢纽值作为各个对象的初始根因分数 R_{ea} 。

[0121] 其中, a 表示对象集合 V 中的任一对象。

[0122] 基于获得的异常传播因子和初始根因分数, 确定每个对象的根因分数 R_x 。

[0123] 具体的, 通过下式得到对象 x 的根因分数 R_x :

$$[0124] \quad \mathcal{R}_x = \varepsilon \mathcal{R}_{ex} + (1 - \varepsilon) \sum_{\forall Y} \gamma_{XY} \mathcal{M}_{xY}^T \mathcal{R}_y$$

[0125] 其中, X, Y 分别表示对象类型集合 A 中类型为 X 的对象集合和类型为 Y 的对象集合, x

表示类型为X的对象集合中的对象,y表示类型为Y的对象集合中的对象; R_x 和 R_y 分别表示对象x和对象y的根因分数; M_{xy} 为邻接矩阵, M_{xy} 中的元素用 m_{xy} 表示,如果对象x与对象类型Y之间存在关系,则 $m_{xy} = \text{Num}(x, Y)$;如果对象x与对象类型Y之间不存在关系,则 $m_{xy} = 0$; $\text{Num}(x, Y)$ 表示对象x与类型为Y的对象集合中所有对象之间的关系数量的总和; γ_{xy} 表示对象类型X与对象类型Y之间的异常传播因子, $\sum_{\forall x} \gamma_{xy} = 1$, ε 表示衰减因子,根据专家知识进行选择。

[0126] 本发明通过结合异质图的对象排序算法,有效解决了初始根因分数未考虑到不同对象类型间关系的问题。

[0127] 基于获得的每个对象的根因分数,选择top-K的根因分数对应的对象作为故障根因定位结果。

[0128] 其中,top-K的根因分数表示前K个最大的根因分数。

[0129] 具体的,将获得的故障根因定位结果以可视化形式显示,如图6所示,供系统管理员参考。

[0130] 实施例三:

[0131] 本实施例提供一种存储介质,其存储有计算机程序;当所述计算机程序被计算机设备中的处理器执行时,计算机设备执行如上述任一项所述的方法。

[0132] 本发明通过采用异质拓扑图,简洁清晰的展示了更细粒度的服务码调用关系和隶属关系;通过融合多维指标的关联特征,有效提高了异质拓扑结构中调用边的指标异常检测的正确率;通过采用异质图的节点排序算法进行根因定位,不仅考虑了异质图中对象异常传播的枢纽值,还考虑了不同对象类型间的异常传播因,系统监控数据通过上述算法处理框架后,结合机器学习算法自动化处理得到当前告警对应的异质故障图和根因系统,并以可视化形式和根因推荐的形式简洁地展示给系统以进行分析和处理,能够辅助管理员高效地定位到故障根源,有效提高了故障根因定位的准确性。

[0133] 为了说明的目的,前述描述使用具体命名以提供对所述实施方案的透彻理解。然而,对于本领域的技术人员而言将显而易见的是,不需要具体细节即可实践所述实施方案。因此,出于例示和描述的目的,呈现了对本文所述的具体实施方案的前述描述。这些描述并非旨在是穷举性的或将实施方案限制到所公开的精确形式。对于本领域的普通技术人员而言将显而易见的是,鉴于上面的教导内容,许多修改和变型是可行的。另外,当在本文中用于指部件的位置时,上文和下文的术语或它们的同义词不一定指相对于外部参照的绝对位置,而是指部件的参考附图的相对位置。

[0134] 此外,前述附图和描述包括许多概念和特征,其可以多种方式组合以实现多种有益效果和优点。因此,可组合来自各种不同附图的特征,部件,元件和/或概念,以产生未必在本说明书中示出或描述的实施方案或实施方式。此外,在任何特定实施方案和/或实施方式中,不一定需要具体附图或说明中所示的所有特征,部件,元件和/或概念。应当理解,此类实施方案和/或实施方式落入本说明书的范围。




图1




图2




图3




图4




图5




图6