



(12)发明专利申请

(10)申请公布号 CN 110532550 A

(43)申请公布日 2019.12.03

(21)申请号 201910742035.5

(22)申请日 2019.08.13

(71)申请人 北京必示科技有限公司

地址 100083 北京市海淀区中关村东路8号
东升大厦A座502室

(72)发明人 刘大鹏 张圣林 李浩达 朱晶
隋楷心

(74)专利代理机构 山东重诺律师事务所 37228
代理人 李常芳

(51)Int.Cl.

G06F 17/27(2006.01)

G06F 16/31(2019.01)


权利要求书2页 说明书5页 附图4页

(54)发明名称

一种基于日志词频树的智能系统日志解析处理方法

(57)摘要

本发明公开了一种基于日志词频树的智能系统日志解析处理方法,所述系统日志处理通过设备自动从系统日志中提取模板,所述提取模板是指系统日志消息中详细信息字段的子类型,所述系统日志消息中详细信息字段的子类型是频繁出现的单词的最长组合,所述提取模板等价于从系统日志消息中识别出频繁出现单词的最长组合,本发明科学合理,使用安全方便,将系统日志消息创建成日志词频树的形式,当有一种新的模板加入时,可以直接根据日志词频树的根节点和子节点对新的模板进行插入处理,避免了当新的模板插入时,需要重新处理和构建整个模板结合,减小了计算机资源的消耗,使得对于系统日志消息的处理更加的快速和准确。



1. 一种基于日志词频树的智能系统日志解析处理方法,其特征在于:所述系统日志处理通过设备自动从系统日志中提取模板;

所述提取模板是指系统日志消息中详细信息字段的子类型;

所述系统日志消息中详细信息字段的子类型是频繁出现的单词的最长组合;

所述提取模板等价于从系统日志消息中识别出频繁出现单词的最长组合。

2. 根据权利要求1所述的一种基于日志词频树的智能系统日志解析处理方法,其特征在于:智能系统日志解析处理方法包括以下步骤:

S1、设定系统日志消息的集合为 $DM=(M_1, M_2, \dots, M_n)$;

S2、设定系统日志消息集合中出现的不同单词的集合 $I=(a_1, a_2, \dots, a_m)$;

S3、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行一次扫描;

S4、通过一次扫描,根据消息类型创建根节点;

S5、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行二次扫描;

S6、对系统日志消息集合中的每个系统日志消息 M_i 进行处理;

S7、对处理之后形成的日志词频树进行修剪;

S8、出现新的子类型消息时,向日志词频树中插入新的节点。

3. 根据权利要求2所述的一种基于日志词频树的智能系统日志解析处理方法,其特征在于:所述步骤S1-S2中,所述系统日志消息的集合设定为 $DM=(M_1, M_2, \dots, M_n)$, $n \in (1, i)$,所述系统日志消息集合中每个 M_i 是一条系统日志消息,所述系统日志消息集合中出现的不同单词的集合设定为 $I=(a_1, a_2, \dots, a_m)$;

所述 $I=(a_1, a_2, \dots, a_m)$ 中一个所述单词A出现的频率等于 $DM=(M_1, M_2, \dots, M_n)$ 这个系统日志消息集合中包含单词A的系统日志消息 M_i 的数量;

所述单词A为系统日志处理中需要提取的模板。

4. 根据权利要求2所述的一种基于日志词频树的智能系统日志解析处理方法,其特征在于:所述步骤S3-S6中,所述日志词频树对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行第一次扫描,所述第一次扫描得出每个单词出现的频率,对每个单词出现的频率进行降序排列;

所述日志词频树进行根节点的创建,所述日志词频树根节点由系统日志消息类型进行标记;

所述日志词频树对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行第二次扫描,所述第二次扫描对每一条系统日志消息 M_i 进行处理,所述第二次扫描对系统日志消息 M_1 进行处理时,根据每个单词的降序排列顺序得到日志词频树根节点的第一条分支,所述第二次扫描对系统日志消息 M_2 进行处理时;

当 M_2 中作为分支的每个单词的降序排列顺序与 M_1 相同时,所述 M_2 与已经存在的 M_1 分支共享一个共同前缀,所述日志词频树需要重新创建一个分支,作为根节点第一条分支的子节点。

5. 根据权利要求2所述的一种基于日志词频树的智能系统日志解析处理方法,其特征在于:所述步骤S7中,所述日志词频树的每个系统日志消息类型有若干个子类型,每个所述子类型有若干个不同的日志消息与之匹配,所述日志词频树的一个根节点有大于三个以上的子节点时,所述子节点三个以上的子节点将全部从日志词频树中删除,所述最后一个子节点变成叶节点。

6. 根据权利要求2所述的一种基于日志词频树的智能系统日志解析处理方法,其特征
在于:所述步骤S8中,一个所述系统日志消息的消息类型是一定的,当操作系统或固件升级
时,会出现新的子类型消息,所述设备生成新的消息模板,匹配新的子类型的系统日志消
息,所述消息模板通过向日志词频树中插入新的子节点来完成。

7. 根据权利要求6所述的一种基于日志词频树的智能系统日志解析处理方法,其特征
在于:所述步骤S8还包括以下步骤:

- A1、根据每个单词出现的频率对单词进行降序排列;
- A2、根据系统日志消息类型确定根节点;
- A3、根据降序排列确定已经存在的分支,确定共同前缀;
- A4、将新的系统日志消息中的分支插入到日志词频树中。

8. 根据权利要求7所述的一种基于日志词频树的智能系统日志解析处理方法,其特征
在于:所述步骤A1-A2中,对新出现的系统日志消息中的单词集合进行降序排列,根据原有
的已经创建的日志词频树确定新出现的系统日志消息的根节点,并对新出现的系统日志消
息进行排序。

9. 根据权利要求7所述的一种基于日志词频树的智能系统日志解析处理方法,其特征
在于:所述步骤A3-A4中,根据降序排序确定共享前缀的前提下的共同分支,确定共享前缀,
即可将新的系统日志消息插入到该共同分支之下,完成系统日志消息的增量式模板学习。

10. 根据权利要求7所述的一种基于日志词频树的智能系统日志解析处理方法,其特征
在于:所述新的系统日志消息在插入时,所述日志词频树的所有子节点都已经被删除。

一种基于日志词频树的智能系统日志解析处理方法

技术领域

[0001] 本发明涉及系统日志解析处理技术领域,具体是一种基于日志词频树的智能系统日志解析处理方法。

背景技术

[0002] 日志是AIOps需要处理常见数据,是程序运行过程中由代码打印出的一些程序完成的任务和系统的状态,从属于非结构化文本的日志数据中提炼特征挑战性大,不能简单采用NLP(自然语言处理)方法,需要首先结合运维领域知识从日志中提炼日志模板(事件),一种通用的系统日志预处理的方法是从历史系统日志消息中提取模板,然后,将系统日志消息映射到模板上,但是,当前提出的模板提取方法或者在学习“正确”模板集合时准确性较低,或者不支持增量式学习,当模板提取方法不支持增量式学习时,如果一种新的模板加入,所有的历史系统日志消息都要被重新处理一遍以重新构建整个模板集合,这对于大型的数据中心的日志分析来说,将消耗太多的计算资源。

[0003] 从日志中提取消息模板会面临如下挑战:

(1)非结构化:交换机系统日志消息通常是非结构化的文本。

[0004] (2)数据量大:数据中心中每天会产生数以千万计的系统日志信息。

[0005] (3)类型多样:交换机日志会随着设备厂商和设备型号的变化而变化。

[0006] 所以,人们急需一种基于日志词频树的智能系统日志解析处理方法来解决上述问题。

发明内容

[0007] 本发明的目的在于提供一种基于日志词频树的智能系统日志解析处理方法,以解决现有技术中提出的当前提出的模板提取方法或者在学习“正确”模板集合时准确性较低,或者不支持增量式学习,当模板提取方法不支持增量式学习的问题。

[0008] 为实现上述目的,本发明提供如下技术方案:一种基于日志词频树的智能系统日志解析处理方法,所述系统日志处理通过设备自动从系统日志中提取模板;

所述提取模板是指系统日志消息中详细信息字段的子类型;

所述系统日志消息中详细信息字段的子类型是频繁出现的单词的最长组合;

所述提取模板等价于从系统日志消息中识别出频繁出现单词的最长组合。

[0009] 根据上述技术方案,智能系统日志解析处理方法包括以下步骤:

S1、设定系统日志消息的集合为 $DM=(M_1, M_2, \dots, M_n)$;

S2、设定系统日志消息集合中出现的不同单词的集合 $I=(a_1, a_2, \dots, a_m)$;

S3、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行一次扫描;

S4、通过一次扫描,根据消息类型创建根节点;

S5、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行二次扫描;

S6、对系统日志消息集合中的每个系统日志消息 M_i 进行处理;

S7、对处理之后形成的日志词频树进行修剪；

S8、出现新的子类型消息时，向日志词频树中插入新的节点。

[0010] 根据上述技术方案，所述步骤S1-S2中，所述系统日志消息的集合设定为 $DM = (M_1, M_2, \dots, M_n)$ ， $n \in (1, i)$ ，所述系统日志消息集合中每个 M_i 是一条系统日志消息，所述系统日志消息集合中出现的不同单词的集合设定为 $I = (a_1, a_2, \dots, a_m)$ ；

所述 $I = (a_1, a_2, \dots, a_m)$ 中一个所述单词A出现的频率等于 $DM = (M_1, M_2, \dots, M_n)$ 这个系统日志消息集合中包含单词A的系统日志消息 M_i 的数量；

所述单词A为系统日志处理中需要提取的模板。

[0011] 根据上述技术方案，所述步骤S3-S6中，所述日志词频树对系统日志消息集合 $DM = (M_1, M_2, \dots, M_n)$ 进行第一次扫描，所述第一次扫描得出每个单词出现的频率，对每个单词出现的频率进行降序排列；

所述日志词频树进行根节点的创建，所述日志词频树根节点由系统日志消息类型进行标记；

所述日志词频树对系统日志消息集合 $DM = (M_1, M_2, \dots, M_n)$ 进行第二次扫描，所述第二次扫描对每一条系统日志消息 M_i 进行处理，所述第二次扫描对系统日志消息 M_1 进行处理时，根据每个单词的降序排列顺序得到日志词频树根节点的第一条分支，所述第二次扫描对系统日志消息 M_2 进行处理时；

当 M_2 中作为分支的每个单词的降序排列顺序与 M_1 相同时，所述 M_2 与已经存在的 M_1 分支共享一个共同前缀，所述日志词频树需要重新创建一个分支，作为根节点第一条分支的子节点。

[0012] 根据上述技术方案，所述步骤S7中，所述日志词频树的每个系统日志消息类型有若干个子类型，每个所述子类型有若干个不同的日志消息与之匹配，为了可以有效的对系统日志消息进行解析和处理，所述日志词频树的一个根节点有大于三个以上的子节点时，所述子节点三个以上的子节点将全部从日志词频树中删除，所述最后一个子节点变成叶节点。

[0013] 根据上述技术方案，所述步骤S8中，一个所述系统日志消息的消息类型是一定的，当操作系统或固件升级时，会出现新的子类型消息，所述设备生成新的消息模板，匹配新的子类型的系统日志消息，所述消息模板通过向日志词频树中插入新的子节点来完成。

[0014] 根据上述技术方案，所述步骤S8还包括以下步骤：

A1、根据每个单词出现的频率对单词进行降序排列；

A2、根据系统日志消息类型确定根节点；

A3、根据降序排列确定已经存在的分支，确定共同前缀；

A4、将新的系统日志消息中的分支插入到日志词频树中。

[0015] 根据上述技术方案，所述步骤A1-A2中，对新出现的系统日志消息中的单词集合进行降序排列，根据原有的已经创建的日志词频树确定新出现的系统日志消息的根节点，并对新出现的系统日志消息进行排序。

[0016] 根据上述技术方案，所述步骤A3-A4中，根据降序排序确定共享前缀的前提下的共同分支，确定共享前缀，即可将新的系统日志消息插入到该共同分支之下，完成系统日志消息的增量式模板学习。

[0017] 根据上述技术方案,所述新的系统日志消息在插入时,所述日志词频树的所有子节点都已经被删除。

[0018] 与现有技术相比,本发明的有益效果是:通过对系统日志消息中的单词进行降序排序,并对单词进行一次扫描和二次扫描,根据系统日志消息类型进行根节点的创建,大大加速了对系统日志消息的解析和处理,并且,将系统日志消息创建成日志词频树的形式,当有一种新的模板加入时,可以直接根据日志词频树的根节点和子节点对新的模板进行插入处理,避免了当新的模板插入时,需要重新处理和构建整个模板结合,减小了计算机资源的消耗,使得对于系统日志消息的处理更加的快速和准确。

附图说明

[0019] 图1为本发明一种基于日志词频树的智能系统日志解析处理方法的步骤示意图;

图2为本发明一种基于日志词频树的智能系统日志解析处理方法步骤S8的示意图;

图3为本发明一种基于日志词频树的智能系统日志解析处理方法 $DM=(M_1, M_2, \dots, M_8)$ 的详细信息和降序排列单词表;

图4为本发明一种基于日志词频树的智能系统日志解析处理方法日志词频树的创建结构示意图;

图5为本发明一种基于日志词频树的智能系统日志解析处理方法 M_{new} 的插入结构示意图。

具体实施方式

[0020] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0021] 实施例一:如图1-2所示,一种基于日志词频树的智能系统日志解析处理方法,系统日志处理通过设备自动从系统日志中提取模板;

提取模板是指系统日志消息中详细信息字段的子类型;

系统日志消息中详细信息字段的子类型是频繁出现的单词的最长组合;

提取模板等价于从系统日志消息中识别出频繁出现单词的最长组合。

[0022] 智能系统日志解析处理方法包括以下步骤:

S1、设定系统日志消息的集合为 $DM=(M_1, M_2, \dots, M_n)$;

S2、设定系统日志消息集合中出现的不同单词的集合 $I=(a_1, a_2, \dots, a_m)$;

S3、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行一次扫描;

S4、通过一次扫描,根据消息类型创建根节点;

S5、对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行二次扫描;

S6、对系统日志消息集合中的每个系统日志消息 M_i 进行处理;

S7、对处理之后形成的日志词频树进行修剪;

S8、出现新的子类型消息时,向日志词频树中插入新的节点。

[0023] 步骤S1-S2中,系统日志消息的集合设定为 $DM=(M_1, M_2, \dots, M_n)$, $n \in (1, i)$, 系统日志

消息集合中每个 M_i 是一条系统日志消息,系统日志消息集合中出现的不同单词的集合设定为 $I=(a_1, a_2, \dots, a_m)$;

$I=(a_1, a_2, \dots, a_m)$ 中一个单词 A 出现的频率等于 $DM=(M_1, M_2, \dots, M_n)$ 这个系统日志消息集合中包含单词 A 的系统日志消息 M_i 的数量;

单词 A 为系统日志处理中需要提取的模板。

[0024] 步骤S3-S6中,日志词频树对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行第一次扫描,第一次扫描得出每个单词出现的频率,对每个单词出现的频率进行降序排列;

日志词频树进行根节点的创建,日志词频树根节点由系统日志消息类型进行标记;

日志词频树对系统日志消息集合 $DM=(M_1, M_2, \dots, M_n)$ 进行第二次扫描,第二次扫描对每一条系统日志消息 M_i 进行处理,第二次扫描对系统日志消息 M_1 进行处理时,根据每个单词的降序排列顺序得到日志词频树根节点的第一条分支,第二次扫描对系统日志消息 M_2 进行处理时;

当 M_2 中作为分支的每个单词的降序排列顺序与 M_1 相同时, M_2 与已经存在的 M_1 分支共享一个共同前缀,日志词频树需要重新创建一个分支,作为根节点第一条分支的子节点。

[0025] 步骤S7中,日志词频树的每个系统日志消息类型有若干个子类型,每个子类型有若干个不同的日志消息与之匹配,为了可以有效的对系统日志消息进行解析和处理,日志词频树的一个根节点有大于三个以上的子节点时,子节点三个以上的子节点将全部从日志词频树中删除,最后一个子节点变成叶节点。

[0026] 步骤S8中,一个系统日志消息的消息类型是一定的,当操作系统或固件升级时,会出现新的子类型消息,设备生成新的消息模板,匹配新的子类型的系统日志消息,消息模板通过向日志词频树中插入新的子节点来完成。

[0027] 步骤S8还包括以下步骤:

A1、根据每个单词出现的频率对单词进行降序排列;

A2、根据系统日志消息类型确定根节点;

A3、根据降序排列确定已经存在的分支,确定共同前缀;

A4、将新的系统日志消息中的分支插入到日志词频树中。

[0028] 步骤A1-A2中,对新出现的系统日志消息中的单词集合进行降序排列,根据原有的已经创建的日志词频树确定新出现的系统日志消息的根节点,并对新出现的系统日志消息进行排序。

[0029] 步骤A3-A4中,根据降序排列确定共享前缀的前提下的共同分支,确定共享前缀,即可将新的系统日志消息插入到该共同分支之下,完成系统日志消息的增量式模板学习。

[0030] 新的系统日志消息在插入时,日志词频树的所有子节点都已经被删除。

[0031] 实施例二:如图3所示,例如图中展示了系统日志消息集合 $DM=(M_1, M_2, \dots, M_8)$,其中,每条系统日志消息都属于“SIF”类型;

首先,对 $DM=(M_1, M_2, \dots, M_8)$ 进行第一次扫描,并且,以每个单词出现的频率的降序得到列表 L ,然后,创建日志词频树的根节点,由每条系统日志消息都属于“SIF”类型得出日志词频树的根节点是“SIF”,然后,对 $DM=(M_1, M_2, \dots, M_8)$ 进行第二次扫描;

对系统日志消息 M_1 进行处理,根据每个单词出现的频率排列处的降序的列表 L ,得到日志词频树的第一条分支;

对系统日志消息M2进行处理,因为M2根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,所以,日志词频树需要创建一个新的分支作为节点“to”的子节点;

对系统日志消息M3进行处理,因为M3根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,并且,M3的新的分支与M1共享一个子节点“Interface”,所以,日志词频树需要创建一个新的分支作为子节点“Interface”的子节点;

对系统日志消息M4进行处理,因为M4根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,并且,M4的新的分支与M2共享一个子节点“Vlan-interface”,所以,日志词频树需要创建一个新的分支作为子节点“Vlan -Interface”的子节点;

对系统日志消息M5进行处理,因为M5根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,并且,M5的新的分支与M1共享一个子节点“down”,所以,日志词频树需要创建一个新的分支作为子节点“down”的子节点;

对系统日志消息M6进行处理,因为M6根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,并且,M6的新的分支与M2共享一个子节点“down”,所以,日志词频树需要创建一个新的分支作为子节点“down”的子节点;

对系统日志消息M7进行处理,因为M7根据每个单词出现的频率排列处的降序的列表L与已经存在的分支共享一个共同前缀,并且,M7的新的分支与M3共享一个子节点“up”,所以,日志词频树需要创建一个新的分支作为子节点“up”的子节点;

对系统日志消息M8进行处理,因为M8根据每个单词出现的频率排列出降序的列表L与已经存在的分支共享一个共同前缀,并且,M8的新的分支与M4共享一个子节点“up”,所以,日志词频树需要创建一个新的分支作为子节点“up”的子节点。

[0032] 如图4所示,通过对系统日志消息集合DM=(M1,M2,⋯,M8)中的每一条系统日志消息进行处理,并通过对日志词频树中的子节点的删除,最后,得到了系统日志消息的日志词频树。

[0033] 如图5所示,假设交换机生成了新的系统日志消息Mnew=“Interface ae1 changed state to RETURN”,首先,根据单词出现的频率排列出降序的列表L,列表L中的Mnew与DM=(M1,M2,⋯,M8)中每条系统日志消息已经存在的分支共享一个共同前缀,并且,Mnew的新的分支与M1共享一个子节点“Interface”,并且,在此之前,日志词频树是图4中最右边的日志词频树,并且,日志词频树上的所有子节点(“ae3”、“ae1”、“vlan22”等)都已经被删除,新的系统日志消息Mnew生成之后,需要将分支“RETURN”、“ae1”插入到日志词频树中,作为子节点“Interface”的子节点;

最终完成增量式模板学习。

[0034] 对于本领域技术人员而言,显然本发明不限于上述示范性实施例的细节,而且在不背离本发明的精神或基本特征的情况下,能够以其他的具体形式实现本发明。因此,无论从哪一点来看,均应将实施例看作是示范性的,而且是非限制性的,本发明的范围由所附权利要求而不是上述说明限定,因此旨在将落在权利要求的等同要件的含义和范围内的所有变化囊括在本发明内。不应将权利要求中的任何附图标记视为限制所涉及的权利要求。




图1




图2

消息编号	详细信息	按照L排序的单词
M ₁	Interface ae3,changed state to down	"changed","state","to","Interface","down","ae3"
M ₂	Vlan-inteface vlan22,changed state to down	"changed","state","to","Vlan-Interface","down","vlan22"
M ₃	Interface ae3,changed state to up	"changed","state","to","Interface","up","ae3"
M ₄	Vlan-inteface vlan22,changed state to up	"changed","state","to","Vlan-Interface","up","vlan22"
M ₅	Interface ae1,changed state to down	"changed","state","to","Interface","down","ae1"
M ₆	Vlan-inteface vlan20,changed state to down	"changed","state","to","Vlan-Interface","down","vlan20"
M ₇	Interface ae1,changed state to up	"changed","state","to","Interface","up","ae1"
M ₈	Vlan-inteface vlan20,changed state to up	"changed","state","to","Vlan-Interface","up","vlan20"

图3




图4




图5