



(12)发明专利

(10)授权公告号 CN 111338915 B

(45)授权公告日 2020.09.01

(21)申请号 202010411127.8

G06F 40/30(2020.01)

(22)申请日 2020.05.15

G06N 3/04(2006.01)

(65)同一申请的已公布的文献号

申请公布号 CN 111338915 A

(56)对比文件

CN 105528280 A,2016.04.27

CN 105528280 A,2016.04.27

(43)申请公布日 2020.06.26

CN 108664374 A,2018.10.16

(73)专利权人 北京必示科技有限公司

CN 108206747 A,2018.06.26

地址 100083 北京市海淀区中关村东路8号

CN 107066302 A,2017.08.18

东升大厦A座4层

审查员 郝宁

(72)发明人 赵能文 刘大鹏 隋楷心 张文池

(74)专利代理机构 北京中知法苑知识产权代理有限公司 11226

代理人 刘敦枫

(51)Int.Cl.

G06F 11/32(2006.01)

G06F 16/33(2019.01)

权利要求书2页 说明书8页 附图5页

(54)发明名称

动态告警定级方法、装置、电子设备以及存储介质

(57)摘要

本发明公开了一种动态告警定级方法、装置,电子设备以及计算机可读存储介质。上述方法包括以下步骤:使用告警的历史数据对排序模型进行训练,得到训练模型;以及使用所述训练模型对告警的在线数据进行排序,得到告警定级。本发明首创性的将动态告警定级问题建模成基于机器学习的排序问题,基于训练模型在线地、自适应地给出告警的严重性定级,定级准确性高,从而使得工程师能够根据告警定级优先处理严重告警,提高故障解决效率。

S1: 使用告警的历史数据对排序模型进行训练,得到训练模型

S2: 使用所述训练模型对告警的在线数据进行排序,得到告警定级

1. 一种动态告警定级方法,其特征在于,所述方法包括以下步骤:
使用告警的历史数据对排序模型进行训练,得到训练模型;以及
使用所述训练模型对告警的在线数据进行排序,得到告警定级;
所述在线数据包括在线告警数据和在线指标数据;
所述使用所述训练模型对告警的在线数据进行排序,得到告警定级的步骤包括:
提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和所述指标特征组合得到在线特征向量;以及
将所述在线特征向量输入所述训练模型,得到所述告警定级;
所述历史数据包括工单、告警数据和指标数据;
所述使用告警的历史数据对排序模型进行训练,得到训练模型的步骤包括:
提取所述工单的标注;
提取所述告警数据的告警特征,并提取所述指标数据的指标特征,将所述告警特征和所述指标特征组合得到特征向量;以及
将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

2. 根据权利要求1所述的动态告警定级方法,其特征在于,
所述告警特征包括以下特征中的至少一项:文本特征、文本熵、时序特征;其中,所述文本特征是采用基于学习的双词主题模型(BTM)获得的;所述文本熵是采用逆文档频率(IDF)计算得到的;所述时序特征包括告警的频率、周期、单位时间告警数量或告警间隔时间;
所述指标特征是采用基于长短期记忆(LSTM)网络的多时间序列异常检测算法获得的。

3. 一种动态告警定级装置,其特征在于,所述装置包括:
离线训练模块,用于使用告警的历史数据对排序模型进行训练,得到训练模型;以及
在线排序模块,用于使用所述训练模型对告警的在线数据进行排序,得到告警定级;
所述在线数据包括在线告警数据和在线指标数据;
所述在线排序模块包括:
在线特征向量提取模块,用于提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和所述指标特征组合得到在线特征向量;以及
定级模块,将所述在线特征向量输入所述训练模型,得到所述告警定级;
所述历史数据包括工单、告警数据和指标数据;
所述离线训练模块包括:
标注提取模块,用于提取所述工单的标注;
特征向量提取模块,用于提取所述告警数据的告警特征,并提取所述指标数据的指标特征,将所述告警特征和所述指标特征组合得到特征向量;以及
模型训练模块,用于将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

4. 根据权利要求3所述的动态告警定级装置,其特征在于,
所述告警特征包括以下特征中的至少一项:文本特征,文本熵,时序特征;其中,所述文本特征是采用基于学习的双词主题模型(BTM)获得的;所述文本熵是采用逆文档频率(IDF)计算得到的;所述时序特征包括告警的频率、周期、单位时间告警数量或告警间隔时间;

所述指标特征是采用基于长短期记忆 (LSTM) 网络的多时间序列异常检测算法获得的。

5. 一种电子设备, 其特征在于, 包括:

至少一个处理器; 以及

与所述至少一个处理器耦合连接的存储器; 其中,

所述存储器存储有计算机程序, 所述计算机程序能够被所述至少一个处理器执行, 以实现权利要求1-2任一项所述的方法。

6. 一种计算机可读存储介质, 其特征在于, 所述计算机可读存储介质中存储有计算机程序, 当所述计算机程序被执行时, 能够实现权利要求1-2任一项所述的方法。

动态告警定级方法、装置、电子设备以及存储介质

技术领域

[0001] 本申请涉及系统告警领域,尤其涉及一种动态告警定级方法、装置、电子设备以及计算机可读存储介质。

背景技术

[0002] 大型的在线服务系统由很多组件组成来支持大量的并发用户。为了保证服务质量和用户体验,需要从各个组件中收集各种监控数据,如指标,日志,调用链等,并手动设置多种告警规则,一旦监控数据违反了这些告警规则(例如CPU利用率超过80%,日志文件中出现fail关键字等)就会生成告警,并发送给工程师进行检查。如果告警比较严重,工程师会创建工单来进行排查和诊断。告警数据可以包含多个属性,例如告警时间、告警内容、告警类型、告警来源系统、告警来源机器、告警级别和告警关闭时间等。

[0003] 由于在线服务的复杂性和动态性,系统可能并发生成大量告警,超出工程师的处理能力。因此,实际中常采用手动方式定义定级规则,将告警分为不同优先级(例如P1-error,P2-warning,P3-info;CPU利用率超过90%是P1,超过70%是P2)。工程师主要关注最高级别的告警,即严重告警。然而即便如此,严重告警的触发量仍然很大。此外,手工定义和维护规则很难有统一标准切换非常消耗人力,基于规则的告警定级方法准确性不高,且无法适应系统的动态变化。

发明内容

[0004] 为解决上述技术问题,本发明实施例提供一种准确的、自适应的告警定级算法,能够自动地对并发的大量告警进行严重性定级,优先把严重的告警推荐给工程师,从而有助于工程师快速发现潜在的故障,减少故障修复时间。

[0005] 本发明的一个方面在于,提供一种动态告警定级方法,所述方法包括以下步骤:

[0006] 使用告警的历史数据对排序模型进行训练,得到训练模型;以及

[0007] 使用所述训练模型对告警的在线数据进行排序,得到告警定级。

[0008] 可选的,所述历史数据包括工单、告警数据和指标数据;

[0009] 所述使用告警的历史数据对排序模型进行训练,得到训练模型的步骤包括:

[0010] 提取所述工单的标注;

[0011] 提取所述告警数据的告警特征,并提取所述指标数据的指标特征,将所述告警特征和指标特征组合得到特征向量;以及

[0012] 将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

[0013] 可选的,所述在线数据包括在线告警数据和在线指标数据;

[0014] 所述使用所述训练模型对告警的在线数据进行排序,得到告警定级的步骤包括:

[0015] 提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和所述指标特征组合得到在线特征向量;以及

[0016] 将所述在线特征向量输入所述训练模型,得到所述告警定级。

[0017] 可选的,所述告警特征包括以下特征中的至少一项:文本特征,文本熵,时序特征;其中,所述文本特征是采用基于学习的双词主题模型(BTM)获得的;所述文本熵是采用逆文档频率(IDF)计算得到的;所述时序特征包括告警的频率、周期、单位时间告警数量或告警间隔时间;

[0018] 所述指标特征是采用基于长短期记忆(LSTM)网络的多时间序列异常检测算法获得的。

[0019] 本发明的另一个方面在于,提供一种动态告警定级装置,所述装置包括:

[0020] 离线训练模块,用于使用告警的历史数据对排序模型进行训练,得到训练模型;以及

[0021] 在线排序模块,用于使用所述训练模型对告警的在线数据进行排序,得到告警定级。

[0022] 可选的,所述历史数据包括工单、告警数据和指标数据;

[0023] 所述离线训练模块包括:

[0024] 标注提取模块,用于提取所述工单的标注;

[0025] 特征向量提取模块,用于提取所述告警数据的告警特征,并提取所述指标数据的指标特征,将所述告警特征和指标特征组合得到特征向量;以及

[0026] 模型训练模块,用于将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

[0027] 可选的,所述在线数据包括在线告警数据和在线指标数据;

[0028] 所述在线排序模块包括:

[0029] 在线特征向量提取模块,用于提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和所述指标特征组合得到在线特征向量;以及

[0030] 定级模块,将所述在线特征向量输入所述训练模型,得到所述告警定级。

[0031] 可选的,所述告警特征包括以下特征中的至少一项:文本特征,文本熵,时序特征;其中,所述文本特征是采用基于学习的双词主题模型(BTM)获得的;所述文本熵是采用逆文档频率(IDF)计算得到的;所述时序特征包括告警的频率、周期、单位时间告警数量或告警间隔时间;

[0032] 所述指标特征是采用基于长短期记忆(LSTM)网络的多时间序列异常检测算法获得的。

[0033] 本发明的另一个方面在于,提供一种电子设备,包括:

[0034] 至少一个处理器;以及

[0035] 与所述至少一个处理器耦合连接的存储器;其中,

[0036] 所述存储器存储有计算机程序,所述计算机程序能够被所述至少一个处理器执行,以实现本发明所述的方法。

[0037] 本发明的另一个方面在于,提供一种计算机可读存储介质,所述计算机可读存储介质中存储有计算机程序,当所述计算机程序被执行时,能够实现本发明所述的方法。

[0038] 本发明利用历史数据中的工单和告警处置记录,自动给每条历史告警标注严重性分数,并且基于数据融合和特征融合的思想,从告警数据和指标数据中提取了一系列可解

释的、有物理意义的特征来表征告警的严重性。本发明首创性的将动态告警定级问题建模成基于机器学习的排序问题,基于训练模型在线地、自适应地给出告警的严重性定级,定级准确性高,从而使得工程师能够根据告警定级优先处理严重告警,提高故障解决效率。

附图说明

- [0039] 图1是本发明实施例中动态告警定级方法的流程图;
- [0040] 图2是本发明实施例中动态告警定级方法的流程图;
- [0041] 图3是本发明实施例中动态告警定级方法的步骤S1的步骤流程图;
- [0042] 图4是本发明实施例中动态告警定级方法的步骤S2的步骤流程图;
- [0043] 图5a是本发明实施例中14个主题(Topic)对应的告警严重性分数(Severity score)柱形图;
- [0044] 图5b是本发明实施例中文本熵(Entropy)对应的告警严重性分数(Severity score)折线图;
- [0045] 图5c是本发明实施例中业务系统异常分数(Multivariate error of business KPIs)和机器异常分数(Multivariate error of server KPIs)对应的告警严重性分数(Severity score)折线图;
- [0046] 图6是本发明实施例中动态告警定级装置的结构图;
- [0047] 图7是本发明实施例中离线训练模块的结构图;
- [0048] 图8是本发明实施例中在线排序模块的结构图。

具体实施方式

[0049] 为使本发明实施例的目的、技术方案和优点更加清楚,下面将结合附图对本发明的具体实施例进行详细的阐述。

[0050] 如图1所示,本发明的技术方案分为离线训练和在线排序两个阶段。在离线训练阶段,由于对于严重告警一般会创建工单,保存历史告警处理记录,因此可以根据历史数据中的工单来获取历史告警数据的严重性分数作为标注;基于数据融合和特征融合的思想,从历史数据的告警数据和指标数据中分别提取特征以获得特征向量,所述特征向量可以用来表征告警的异常程度;根据获得的标注和特征向量,对排序模型进行训练,可以获得训练模型。在在线排序阶段,对实时到达的告警数据,用同样的特征提取方法获得特征向量,输入到经过学习的排序模型中,排序模型会输出当前时刻并发的大量告警的严重性定级,从而可以引导工程师,优先处理严重性较高的告警。

[0051] 依据本发明的一个方面,提供一种动态告警定级方法。

[0052] 如图2所示,所述方法具体包括以下步骤:

[0053] S1:使用告警的历史数据对排序模型进行训练,得到训练模型;

[0054] S2:使用所述训练模型对告警的在线数据进行排序,得到告警定级。

[0055] 在一个实施例中,告警的历史数据可以包括工单,告警数据和指标数据等,告警的在线数据可以包括在线告警数据和在线指标数据等。

[0056] 如图3所示,所述S1步骤进一步包括:

[0057] S101:提取所述工单的标注;

[0058] S102:提取所述告警数据的告警特征,并提取所述指标数据的指标特征,将所述告警特征和指标特征组合得到特征向量;以及

[0059] S103:将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

[0060] 如图4所示,所述S2步骤进一步包括:

[0061] S201:提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和指标特征组合得到在线特征向量;以及

[0062] S202:将所述在线特征向量输入所述训练模型,得到所述告警定级。

[0063] 以下对于工单的标注、告警特征和指标特征的获取方法进行详细阐述。

[0064] 一、标注

[0065] 本发明利用历史数据中的工单,对历史告警数据的严重性分数打标。一般而言,对于历史上的告警,工程师会排查告警并联系相关的管理员进行处置,然后记录下处置记录,严重的告警会创建工单,由专门负责的人进行跟进和排查。工单的处置记录是由人手工填写的,可以较为真实可靠地反映该条告警的严重性。可以利用基于TF-IDF和k-means的文本聚类的方法,对工单的告警处置记录进行聚类,对聚类得到的每个簇内的告警分别进行统一的严重性打分,所述严重性得分即为工单的标注。下面展示了告警处置记录的几个类别和对应的严重性打分,其中1的严重性最高,0的严重性最低。比如,若某条告警创建了工单,那么这条告警经过工程师确定为严重性级别较高;若某条告警在白名单里或者没有任何处理记录,则其严重性会比较低。

[0066] 第一, None (0)

[0067] 第二, 告警在白名单 (0.1)

[0068] 第三, 告警已经自动恢复 (0.2)

[0069] 第四, 联系应用管理员, 确认对业务影响 (0.4)

[0070] 第五, 已知原因, 告警被修复 (0.6)

[0071] 第六, 联系应用管理员, 对业务有影响, 目前已修复 (0.8)

[0072] 第七, 创建事件单, 持续跟进 (1)

[0073] 二、告警特征

[0074] 在从告警数据中提取告警特征之前, 需要先对告警数据做一些预处理。如果告警数据是中英文混杂的文本, 需要借用中文分词(如结巴分词)技术对告警内容进行分词。此外, 告警内容一般是半结构化的文本, 包含了较多停用词、符号和变量。因此需要去掉没有意义的停用词和符号, 然后借鉴日志模板提取的方法, 对告警数据进行处理, 过滤掉变量, 从而得到告警模板。之后, 可以从以下方面来提取告警特征:

[0075] 第一, 主题特征

[0076] 告警模板可以认为是运维领域的一种短文本, 不同的告警内容包含的语义信息也不一样, 不同的语义也往往对应着不同的严重性。因此, 本发明首次将自然语言处理中流行的主题模型应用到告警数据中, 来从告警内容中提取隐藏的语义特征。考虑到告警内容的短文本特征, 直接采用传统的LDA(Latent Dirichlet Allocation)主题模型效果并不理想, 因此, 可以采用针对短文本设计的双词主题模型(Biterm Topic Model, BTM)。通过告警数据的预处理, 克服了告警数据中存在的一些问题(如中英文混杂, 停用词等), 使得BTM能

够挖掘出可解释的语义信息。给定一个主题个数 n , BTM能发现隐藏的主题和每个主题对应的关键字, 根据一致性得分 (coherence score) 来选择最优的主题个数。下面展示了BTM在实际告警数据中学习到的主题和对应的关键字 ($n=14$)。

[0077] T#1:oracle,连接,数据库,空间,pool,进程,锁...

[0078] T#2:syslog,告警,error,堆栈,记录,硬件,告警...

[0079] T#3:监控,环境,主机,电池,湿度,机房,电压...

[0080] ...

[0081] T#13:系统,交易量,响应,阈值,时间,业务,值为...

[0082] T#14:交换机,虚拟,通信,连接,响应,ping,网络...

[0083] 可以看出BTM给出的关键字都是具有一定物理意义和可解释性, 例如可以推测主题1 (T#1) 与数据库告警相关, 主题2 (T#2) 与系统日志告警相关。对于一条告警信息, BTM可以给出其属于每个主题的概率, 而该对应于每个主题的概率即为该条告警信息的主题特征。例如对于一条告警: “oracle表空间使用率达到78%, 超过阈值”, 上述BTM可以给出的主题特征, 该主题特征是一个长度为14的向量 $[0.78, 0.05, 0.02, \dots, 0.19, 0.04]$ 。

[0084] 图5a展示了上述的14个主题 (Topic) 对应的告警严重性分数 (Severity score)。可以看出主题特征对于告警严重性的区分是有意义的。

[0085] 第二, 文本熵

[0086] 告警内容往往是多个单词的组合, 不同单词在识别严重告警上具有不同的权重, 例如“中断”可能“端口”更严重。因此可以提取告警数据的文本熵, 用来度量告警的严重性程度。在文本挖掘技术中, 逆文档频率 (Inverse Document Frequency, IDF) 是一种常用的衡量单词重要性的方法, 该方法可以降低常用单词的权重, 增加稀有单词的权重。对于单词 ω , 计算其单词熵:

$$[0087] \quad IDF(\omega) = \log \frac{N}{N_{\omega} + 1}$$

[0088] 其中 N 是所有告警的个数, N_{ω} 是包含单词 ω 的告警的个数。根据该单词熵可知, 经常在告警中出现的单词具有较低的严重性。而某条告警的文本熵由其包含的所有单词熵的平均值计算得到。

[0089] 图5b展示了文本熵 (Entropy) 对应的告警严重性分数 (Severity score)。可以看出当文本熵的值增大时, 对应的告警严重性分数也有增大的趋势。

[0090] 第三, 时序特征

[0091] 时序特征可以包括告警发生的频率、周期、告警数量、间隔时间等。

[0092] 频率: 通常, 一个告警在历史上发生的频率越高 (如: CPU使用率超过阈值 i 值 i), 其严重性会相对较低; 相反, 如果一个告警在历史上很少出现 (低频告警, 如服务器宕机), 则其严重性可能会相对较高, 需要引起工程师的关注。

[0093] 周期: 一些告警的发生是有周期性的, 例如每天夜里的批处理任务都会引发CPU使用率高报警, 这种周期性的告警一般是冗余的。对于一个告警 a , 我们可以获得时间序列 $C(a) = \{c^1(a), c^2(a), \dots, c^k(a)\}$, 其中 $c^k(a)$ 是该告警在第 k 个时间片发生的次数。显然, 如果告警 a 是周期性的, 那么对应的时间序列 $C(a)$ 也是周期性的。

[0094] 采用自相关函数(Auto Correlation Function, ACF)来表征时间序列的周期性。当给定具有长度N和不同滞后时间l的时间序列x(i), 计算:

$$[0095] \quad ACF(l) = \frac{\sum_{i=0}^{N-1} x(i)x(i+l)}{N}, l=1, 2, \dots, \frac{N-1}{2}$$

[0096] 如果时间序列是周期的且周期为T, 那么ACF(l) 会在T, 2T, 3T...处表现出尖峰。因此可以用ACF(l) 的最大值来表征告警的周期性。

[0097] 告警数量: 一般而言, 短时间内发生了大量的告警时, 意味着可能发生了严重故障, 需要引起工程师的关注。

[0098] 间隔时间: 间隔时间是当前告警与之前一个告警之间的时间间隔。通常, 如果较长时间间隔内没有告警而突然出现一个告警时, 需要引起工程师的关注。

[0099] 第四, 其他特征

[0100] 除了上述的特征类型, 还可以从告警数据自带的一些其他属性提取一些关键特征, 例如:

[0101] 基于规则的严重性: 告警数据自带的基于规则的严重性对告警定级有一定的参考意义;

[0102] 告警时间: 告警的发生时间对告警的严重性也有影响, 比如业务高峰期的告警相对来说更重要; 根据告警发出的时间, 可以提取了一系列的时间特征, 例如: 工作日/节假日, 白天/晚上, 是否在业务高峰期等;

[0103] 告警类型: 一般而言, 应用类的告警因为和服务质量强相关, 所以会重要一些。

[0104] 三、指标特征

[0105] 一些关键业务指标能够直接的反映系统的健康状态。当一个告警发生时, 如果对应业务系统的关键业务指标(如交易量、响应时间、成功率等)和机器的关键指标(CPU使用率、内存使用率等)发生了较大的异常, 那么这个告警大概率是严重告警。可以采用了基于长短期记忆(Long Short Term Memory, LSTM)网络的多时间序列异常检测算法来捕获每个关键业务指标和机器指标对应的异常分数和整体业务系统的异常分数, 作为指标特征。

[0106] 图5c展示了业务系统异常分数(Multivariate error of business KPIs)和机器异常分数(Multivariate error of server KPIs) 对应的告警严重性分数(Severity score)。可以看出系统的异常分数越高, 告警严重性程度也越高。

[0107] 依据本发明的一个方面, 提供一种动态告警定级装置。

[0108] 如图6所示, 所述装置包括:

[0109] 离线训练模块10, 用于使用告警的历史数据对排序模型进行训练, 得到训练模型; 以及

[0110] 在线排序模块20, 用于使用所述训练模型对告警的在线数据进行排序, 得到告警定级。

[0111] 在一个实施例中, 所述历史数据包括工单、告警数据和指标数据。

[0112] 如图7所示, 所述离线训练模块10包括:

[0113] 标注提取模块101, 用于提取所述工单的标注;

[0114] 特征向量提取模块102, 用于提取所述告警数据的告警特征, 并提取所述指标数据

的指标特征,将所述告警特征和指标特征组合得到特征向量;以及

[0115] 模型训练模块103,用于将所述标注和所述特征向量输入所述排序模型,对所述排序模型进行训练,得到所述训练模型。

[0116] 在一个实施例中,所述在线数据包括在线告警数据和在线指标数据。

[0117] 如图8所示,所述在线排序模块20包括:

[0118] 在线特征向量提取模块201,用于提取所述在线告警数据的告警特征,并提取所述在线指标数据的指标特征,将所述告警特征和所述指标特征组合得到在线特征向量;以及

[0119] 定级模块202,将所述在线特征向量输入所述训练模型,得到所述告警定级。

[0120] 依据本发明的另一个方面,提供一种电子设备,其特征在于,包括:

[0121] 至少一个处理器;以及

[0122] 与所述至少一个处理器耦合连接的存储器;其中,

[0123] 所述存储器存储有计算机程序,所述计算机程序能够被所述至少一个处理器执行,以实现本发明所述的方法。

[0124] 依据本发明的另一个方面,提供一种计算机可读存储介质,其特征在于,所述计算机可读存储介质中存储有计算机程序,当所述计算机程序被执行时,能够实现本发明所述的方法。

[0125] 本领域普通技术人员可以意识到,结合本文中所公开的实施例描述的各示例的模块及算法步骤,能够以电子硬件、或者计算机软件和电子硬件的结合来实现。这些功能究竟以硬件还是软件方式来执行,取决于技术方案的特定应用和设计约束条件。专业技术人员可以对每个特定的应用来使用不同方法来实现所描述的功能,但是这种实现不应认为超出本发明的范围。

[0126] 所属领域的技术人员可以清楚地了解到,为描述的方便和简洁,上述描述的装置和设备的具体工作过程,可以参考前述方法实施例中的对应过程,在此不再赘述。

[0127] 在本申请所提供的实施例中,应该理解到,所揭露的装置和方法,可以通过其它的方式实现。例如,以上所描述的装置实施例仅仅是示意性的,例如,所述模块的划分,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式,例如多个模块或组件可以结合或者可以集成到另一个系统,或一些特征可以忽略,或不执行。另一点,所显示或讨论的相互之间的耦合或直接耦合或通信连接可以是通过一些接口,装置或模块的间接耦合或通信连接,可以是电性,机械或其它的形式。

[0128] 所述作为分离部件说明的模块可以是或者也可以不是物理上分开的,作为模块显示的部件可以是或者也可以不是物理模块,即可以位于一个地方,或者也可以分布到多个网络模块上。可以根据实际的需要选择其中的部分或者全部模块来实现本发明实施例方案的目的。

[0129] 另外,在本发明各个实施例中的各功能模块可以集成在一个处理模块中,也可以是各个模块单独物理存在,也可以两个或两个以上模块集成在一个模块中。

[0130] 所述功能如果以软件功能模块的形式实现并作为独立的产品销售或使用,可以存储在一个计算机可读取存储介质中。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是

人计算机,服务器,或者网络设备等)执行本发明各个实施例节能信号发送/接收的方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、ROM、RAM、磁碟或者光盘等各种可以存储程序代码的介质。

[0131] 以上描述仅为本申请的较佳实施例以及对所运用技术原理的说明。本领域技术人员应当理解,本申请中所涉及的发明范围,并不限于上述技术特征的特定组合而成的技术方案,同时也应涵盖在不脱离所述发明构思的情况下,由上述技术特征或其等同特征进行任意组合而形成的其它技术方案。例如上述特征与本申请中公开的(但不限于)具有类似功能的技术特征进行互相替换而形成的技术方案。




图1




图2



图3




图4




图5a




图5b




图5c



图6




图7




图8