



(12) 发明专利申请

(10) 申请公布号 CN 112905671 A

(43) 申请公布日 2021.06.04

(21) 申请号 202110313319.X

(22) 申请日 2021.03.24

(71) 申请人 北京必示科技有限公司

地址 100083 北京市海淀区中关村东路8号
东升大厦A座4层

申请人 国家计算机网络与信息安全管理中心

(72) 发明人 张文池 王泓琳 陈哲康 周波
王勇 刘大鹏

(74) 专利代理机构 北京华创智道知识产权代理
事务所(普通合伙) 11888
代理人 彭随丽

(51) Int.Cl.

G06F 16/2458 (2019.01)

G06K 9/62 (2006.01)

权利要求书2页 说明书10页 附图3页

(54) 发明名称

时间序列异常处理方法、装置、电子设备及
存储介质

(57) 摘要

本发明提供一种时间序列异常处理方法、装置、电子设备及计算机可读存储介质。其中,时间序列异常处理方法,包括步骤:获取时间序列数据,对所述时间序列数据训练,构建模型;根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;判断被推荐的所述部分异常数据是否合理,然后反馈判断结果;根据所述判断结果优化所述模型,然后继续检测实时时间序列数据。根据本发明的时间序列异常处理方法,对数据没有明显的偏向性,能够适配具有特定场景语义的指标,能应对非传统互联网领域的运维需求,具有更高的可扩展性,具有普适性,给出的异常结果能够给出具体的异常原因。



1. 一种时间序列异常处理方法,其特征在于,包括以下步骤:

获取时间序列数据,对所述时间序列数据训练,构建模型;

根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;

判断被推荐的所述部分异常数据是否合理,然后反馈判断结果;

根据所述判断结果优化所述模型,然后继续检测实时时间序列数据。

2. 根据权利要求1所述的时间序列异常处理方法,其特征在于,获取时间序列数据包括获取规则的小规模时间序列数据和获取不规则的大规模时间序列数据,获取不规则的大规模时间序列数据时,对所有时间序列数据聚类处理,然后对各类时间序列数据训练,构建模型。

3. 根据权利要求2所述的时间序列异常处理方法,其特征在于,所述聚类处理是通过DBSCAN来捕获待训练时间序列数据之间的关联关系,将形状近似和周期性相符的数据聚类。

4. 根据权利要求3所述的时间序列异常处理方法,其特征在于,在所述聚类处理过程中,在计算时间序列数据的近似度时,使用动态时间规整算法计算时间序列数据之间的距离。

5. 根据权利要求4所述的时间序列异常处理方法,其特征在于,根据所述时间序列数据的类型,选取能够代表相应类型的时间序列数据的特征数据进行训练,构建模型。

6. 根据权利要求5所述的时间序列异常处理方法,其特征在于,采用稳健随机砍伐森林选取所有所述特征数据进行训练,所有所述特征数据经过迭代得到多个决策树,多个所述决策树组成决策森林,然后通过所述决策森林投票决定实时时间序列数据中是否存在异常数据。

7. 根据权利要求6所述的时间序列异常处理方法,其特征在于,在构建所述决策树时,所述RRCF选择切分所述特征数据的切分维度,在所述切分维度下,所述RRCF选取所述特征

数据的概率为 $p_i = \frac{g_i}{\sum_j g_j} + \frac{l_i}{\sum_j l_j}$, $g_i = \max_{x \in S} x_j - x_{j-1}$; 其中i为特征数据, p_i 表示特征i被选

择的概率,概率值为0到1之间; l_i 表示特征i在训练的样本集中,计算得到的特征集合里,最大值和最小值的差; g_i 表示特征i在训练的样本集中,计算得到的特征集合里,按特征大小排序后,相邻的两个特征值之间最大的差值; $\sum g_i$ 代表每个特征维度j计算出来的 g_j 求和 $\sum l_j$ 代表每个特征维度j计算出来的 l_j 求和。

8. 根据权利要求7所述的时间序列异常处理方法,其特征在于,所述RRCF将所述切分维度上的所述特征数据等分,等分为N个间隔 $[l_0, h_0, l_1, h_1, \dots, l_{N-1}, h_{N-1}]$, 并计算每个间隔的

密度 $d_i = \text{Count}(p, p \in [l_i, h_i])$, 其中每个所述间隔被选择的概率为 $\frac{d_i}{\sum_j d_j}$, 最终从被选择的

所述间隔中随机挑选切分点 $X_i \sim \text{Uniform}[l_i, h_i]$; 其中, l_0 和 h_{N-1} 分别代表针对训练集求解的特征维度中, l_0 表示特征的最小值, h_{N-1} 代表特征的最大值,两者作差,除以N,等分为N个间隔。

9. 根据权利要求8所述的时间序列异常处理方法,其特征在于,存在所述异常数据时,

利用所述切分点计算所述异常数据的异常分数 $CoDisp$,计算所述异常分数 $CoDisp$ 时,计算所述切分点的兄弟子树和父亲子树所包含所述异常数据数量的比例 $CoDisp_{Node}$,选择最大的比例 $CoDisp_{Node}$,异常数据 x_i 的异常分数为 $CoDisp_{x_i} = \overline{CoDisp_T}, T \in forest$ 。

10. 根据权利要求9所述的时间序列异常处理方法,其特征在于,所述推荐部分异常数据为选择所述异常数据中推测为最异常的多个片段;或者

所述推荐部分异常数据为选择所述异常数据中最不确定的多个片段,获取所述多个片段的标注后进行推荐;或者

所述推荐部分异常数据为根据所述异常分数将所述异常数据切分为多组,每组获取多个片段,获取所述片段的标注后进行推荐。

11. 根据权利要求10所述的时间序列异常处理方法,其特征在于,所述模型获取 n 个标注片段的异常数据后与所述模型的决策森林中的 m 棵决策树共同组成异常分数矩阵 $CoDisp_M[x_i][tree_j]$,对于每个异常数据 x_i ,若反馈判断结果为真阳,则决策树 $tree_j$ 的权重为 $tw_j = tw_j + \delta \times CoDisp_M[x_i][tree_j]$,根据反馈判断结果选择更高权重的决策树,从而优化所述模型。

12. 一种时间序列异常处理装置,其特征在于,包括:

数据处理模块,用于获取时间序列数据,对时间序列数据训练,构建模型;

异常数据检测推荐模块,根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;

异常数据判断反馈模块,判断所述部分异常数据是否合理,然后反馈判断结果;

模型优化模块,根据所述反馈判断结果优化所述模型,然后继续检测实时时间序列数据。

13. 根据权利要求12所述的时间序列异常处理装置,其特征在于,还包括

数据分类处理模块,用于获取不规则的大规模时间序列数据,对所有时间序列数据聚类处理,然后对各类时间序列数据训练,构建模型。

14. 一种电子设备,其特征在于,包括处理器、存储器及存储在所述存储器上并可在所述处理器上运行的计算机程序,所述计算机程序被所述处理器执行时实现如权利要求1至11中任一项所述的时间序列异常处理方法。

15. 一种计算机可读存储介质,其特征在于,所述计算机可读存储介质上存储计算机程序,所述计算机程序被处理器执行时实现如权利要求1至11中任一项所述的时间序列异常处理方法。

时间序列异常处理方法、装置、电子设备及存储介质

技术领域

[0001] 本发明涉及数据处理技术领域,尤其涉及一种时间序列异常处理方法、装置、电子设备及计算机可读存储介质。

背景技术

[0002] 现代软件企业往往依赖于大量应用服务,这些服务安装在大量基础设施上,包括物理机、虚拟机、容器上。要保证这些高级别服务和系统的可靠性,运维人员需要监控、检查基础设施的运行状况。在日常的运维管理工作中,运维工程师通常监视并收集基础设施的各种性能指标。同一台机器上的不同的指标描述了这台机器的健康状况,例如,机器常常具备内存使用率、CPU使用率和磁盘使用率等指标,实际运行中,由于外部攻击、磁盘介质老化、性能持续过载等引发的故障,机器的可用性将受到严重挑战,此时这些监控指标也将反映出异常。针对时间序列指标的异常检测非常重要,它能够帮助运维团队及早发现故障,从而提高故障发生到排障解决的效率。

[0003] 时间序列指标的异常检测问题在学术界也广为关注,近几年针对时序指标异常检测的算法被大量提出,但受限于算法效果和检测性能,这些方法依然无法达到实际落地应用的要求。考虑到运维工作要监控和排查的指标数量极多,人为提供指标标注是不切实际的,因此有监督异常检测方法难以实践,必须采用无监督学习的方式。此外,时间序列异常检测的场景千差万别,服务的业务对象和负载存在很大差异,指标所表现出的趋势和特点有时还具备强烈的业务相关性,因此异常检测方法需要具备高效收集运维专家反馈从而获取运维专家知识的能力。

[0004] 以下表1列举了目前学术界最先进的无监督时间序列异常检测算法,这些算法多数采用深度学习模型,需要庞大的计算资源以支持训练,计算性能有待提高,并且用户反馈无法直接应用到深度学习框架优化中。采用传统无监督统计学习的方法需要大量的人工调参,且效果参差不齐。这些算法还对数据有明显的偏向性,每种算法都在特定的数据类型上表现优秀,但不具备普适性,给出的异常结果也难以解释具体的异常原因。

[0005]

特性	回归统计学习	传统无监督学习	无监督深度生成模型
容量高	差	一般	优秀
无需调参	差	优秀	一般
无需标注	优秀	优秀	优秀
检测速度快	优秀	一般	一般
训练资源低	优秀	一般	差
训练时间短	优秀	一般	差
可人工调节	差	一般	差

[0006] 表1

发明内容

[0007] 本发明的目的在于解决背景技术中的至少一个技术问题,提供一种时间序列异常处理方法、时间序列异常处理装置、电子设备及计算机可读存储介质。

[0008] 为实现上述目的,本发明提供一种时间序列异常处理方法,包括以下步骤:

[0009] 获取时间序列数据,对所述时间序列数据训练,构建模型;

[0010] 根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;

[0011] 判断被推荐的所述部分异常数据是否合理,然后反馈判断结果;

[0012] 根据所述判断结果优化所述模型,然后继续检测实时时间序列数据。

[0013] 根据本发明的一个方面,获取时间序列数据包括获取规则的小规模时间序列数据和获取不规则的大规模时间序列数据,获取不规则的大规模时间序列数据时,对所有时间序列数据聚类处理,然后对各类时间序列数据训练,构建模型。

[0014] 根据本发明的一个方面,所述聚类处理是通过DBSCAN来捕获待训练时间序列数据之间的关联关系,将形状近似和周期性相符的数据聚类。

[0015] 根据本发明的一个方面,在所述聚类处理过程中,在计算时间序列数据的近似度时,使用DTW计算时间序列数据之间的距离。

[0016] 根据本发明的一个方面,根据所述时间序列数据的类型,选取能够代表相应类型的时间序列数据的特征数据进行训练,构建模型。

[0017] 根据本发明的一个方面,采用RRCF选取所有所述特征数据进行训练,所有所述特征数据经过迭代得到多个决策树,多个所述决策树组成决策森林,然后通过所述决策森林投票决定实时时间序列数据中是否存在异常数据。

[0018] 根据本发明的一个方面,在构建所述决策树时,在构建所述决策树时,所述RRCF选择切分所述特征数据的切分维度,在所述切分维度下,所述RRCF选取所述特征数据的概率

为 $p_i = \frac{g_i}{\sum_j g_j} + \frac{l_i}{\sum_j l_j}$, $g_i = \max_{x \in S} x_j - x_{j-1}$; 其中 i 为特征数据, p_i 表示特征 i 被选择的概率,

概率值为0到1之间; l_i 表示特征 i 在训练的样本集中,计算得到的特征集合里,最大值和最小值的差; g_i 表示特征 i 在训练的样本集中,计算得到的特征集合里,按特征大小排序后,相邻的两个特征值之间最大的差值; $\sum g_j$ 代表每个特征维度 j 计算出来的 g_j 求和 $\sum l_j$ 代表每个特征维度 j 计算出来的 l_j 求和。

[0019] 根据本发明的一个方面,所述RRCF将所述切分维度上的所述特征数据等分,等分为 N 个间隔 $[l_0, h_0, l_1, h_1, \dots, l_{N-1}, h_{N-1}]$, 并计算每个间隔的密度 $d_i = \text{Count}(p, p \in [l_i, h_i])$,

其中每个所述间隔被选择的概率为 $\frac{d_i}{\sum_j d_j}$, 最终从被选择的所述间隔中随机挑选切分点 $X_i \sim$

$\text{Uniform}[l_i, h_i]$; 其中, l_0 和 h_{N-1} 分别代表针对训练集求解的特征维度中, l_0 表示特征的最小值, h_{N-1} 代表特征的最大值, 两者作差, 除以 N , 等分为 N 个间隔。

[0020] 根据本发明的一个方面, 存在所述异常数据时, 利用所述切分点计算所述异常数据的异常分数 CoDisp , 计算所述异常分数 CoDisp 时, 计算所述切分点的兄弟子树和父亲子树所包含所述异常数据数量的比例 $\text{CoDisp}_{\text{Node}}$, 选择最大的比例 $\text{CoDisp}_{\text{Node}}$, 异常数据 x_i 的异

常分数为 $CoDisp_{x_i} = \overline{CoDisp_T}, T \in forest$ 。

[0021] 根据本发明的一个方面,所述推荐部分异常数据为选择所述异常数据中最异常的多个片段,获取所述多个片段的标注后进行推荐;或者

[0022] 所述推荐部分异常数据为选择所述异常数据中最不确定的多个片段,获取所述多个片段的标注后进行推荐;或者

[0023] 所述推荐部分异常数据为根据所述异常分数将所述异常数据切分为多组,每组获取多个片段,获取所述片段的标注后进行推荐。

[0024] 根据本发明的一个方面,所述模型获取n个标注片段的异常数据后与所述模型的决策森林中的m棵决策树共同组成异常分数矩阵 $CoDisp_M[x_i][tree_j]$,对于每个异常数据 x_i ,若反馈判断结果为真阳,则决策树 $tree_j$ 的权重为 $tw_j = tw_j + \delta \times CoDisp_M[x_i][tree_j]$,根据反馈判断结果选择更高权重的决策树,从而优化所述模型。

[0025] 为实现上述目的,本发明还提供一种时间序列异常处理装置,包括:

[0026] 数据处理模块,用于获取时间序列数据,对时间序列数据训练,构建模型;

[0027] 异常数据检测推荐模块,根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;

[0028] 异常数据判断反馈模块,判断所述部分异常数据是否合理,然后反馈判断结果;

[0029] 模型优化模块,根据所述反馈判断结果优化所述模型,然后继续检测实时时间序列数据。

[0030] 根据本发明的一个方面,还包括:

[0031] 数据分类处理模块,用于获取不规则的大规模时间序列数据,对所有时间序列数据聚类处理,然后对各类时间序列数据训练,构建模型。

[0032] 为实现上述目的,本发明还提供一种电子设备,包括处理器、存储器及存储在所述存储器上并可在所述处理器上运行的计算机程序,所述计算机程序被所述处理器执行时实现上述时间序列异常处理方法。

[0033] 为实现上述目的,本发明还提供一种计算机可读存储介质,所述计算机可读存储介质上存储计算机程序,所述计算机程序被处理器执行时实现上述时间序列异常处理方法。

[0034] 根据本发明的一个方案,由于生产环境中要监控的时间序列数量极多,每个生产单元都可能产生几十甚至上百个监控指标数据,这些指标数据需要全部被监控,若分别针对性训练,得到的模型数量和所消耗的资源都会极其庞大,现有的运维资源较难支撑。为此,在指标数据进行针对性训练阶段之前,本发明首先对数据进行聚类,这样能够使得检测处理时间大大减少,能够快速准确地处理异常。

[0035] 根据本发明的一个方案,提出特征数据选择阶段,根据指标的统计信息及特点,针对性提取更契合的特征数据,从而提高模型准确率。

[0036] 根据本发明的一个方案,选择最异常的30个片段,获取这些异常片段的标注能够进一步肯定显式异常、降低假阳率。

[0037] 根据本发明的一个方案,选择最不确定的30个片段(即围绕异常判定阈值附近的),这些标注能够帮助模型明确分类边界,提高模糊异常的识别准确率。

[0038] 根据本发明的一个方案,根据异常分数将异常数据切分为10组,每组获取至多3个

片段,这些标注能够捕获例如判断反馈模块对不同异常判定条件的态度,从而帮助模型确定最佳的阈值选择范围。

[0039] 根据本发明的一个方案,本发明提出了一个无监督的、白盒的、准确的时间序列异常处理方法,配合主动学习,能够主动、高效收集反馈信息。该方法在传统无监督学习框架的基础上,引入了主动学习阶段,向判断反馈部分(例如判断反馈模块或者运维人员)主动推荐异常并获取反馈,进而修正模型,提高准确率。本发明保留了传统无监督学习在调参、标注方面的优势,针对性设计了标注反馈应用策略,进一步优化了模型的召回率、检测速度和容量。

[0040] 根据本发明的一个方案,本发明的处理方法对数据没有明显的偏向性,能够适配具有特定场景语义的指标,能应对非传统互联网领域的运维需求,具有更高的可扩展性,具有普适性,给出的异常结果能够给出具体的异常原因。

[0041] 根据本发明的一个方案,在1个公开数据集和2个商业银行实际生产环境的时间序列数据上经过测试,本发明能够准确地检测并解释异常,最终在两个数据集上达到了0.81和0.89的F1-score。本发明的处理方法表现的比现有方法更好,相比传统无监督异常处理方法,最佳F1-score在两个数据集上提升了0.19到0.5不等,检测时间缩短了58%。

附图说明

[0042] 图1示意性表示根据本发明的一种实施方式的时间序列异常处理方法的流程图;

[0043] 图2示意性表示相同交换机采集的近似指标图;

[0044] 图3-图5示意性表示三种不同的异常片段主动推荐机制图;

[0045] 图6示意性表示根据本发明的一种实施方式的时间序列异常处理装置的功能结构图。

具体实施方式

[0046] 现在将参照示例性实施例来论述本发明的内容。应当理解,论述的实施例仅是为了使得本领域普通技术人员能够更好地理解且因此实现本发明的内容,而不是暗示对本发明的范围的任何限制。

[0047] 如本文中所使用的,术语“包括”及其变体要被解读为意味着“包括但不限于”的开放式术语。术语“基于”要被解读为“至少部分地基于”。术语“一个实施例”和“一种实施例”要被解读为“至少一个实施例”。

[0048] 针对上述背景技术中所述的现有技术中存在的缺陷,本发明提供一种批处理任务时间监控方法,该监控方法可实现批处理任务的时间预测和批处理任务的异常检测,根据预测和检测结果更新任务模型或者产生告警。

[0049] 图1示意性表示根据本发明的一种实施方式的时间序列异常处理方法的流程图。如图1所示,根据本发明的一种实施方式的时间序列异常处理方法,包括以下步骤:

[0050] a. 获取时间序列数据,对时间序列数据训练,构建模型;

[0051] b. 根据所述模型检测实时获得的时间序列数据中是否存在异常数据,若存在,则推荐部分异常数据;

[0052] c. 判断被推荐的所述部分异常数据是否合理,然后反馈判断结果;

[0053] d.根据所述判断结果优化所述模型,然后继续检测实时时间序列数据。

[0054] 实际上,时间序列数据可以用 x 表示, $x = \{x_1, x_2, \dots, x_N\}$, N 是数据 x 的长度,任一时刻 t 的数据点 x_t 是一个具体的数据数值。时间序列可以从很多来源采集而来,例如网络、交易链路、请求日志等。相同来源的时间序列数据有较大几率具有类似的特性。

[0055] 由于生产环境中要监控的时间序列数量极多,每个生产单元都可能产生几十甚至上百个监控指标数据,这些指标数据需要全部被监控,若分别针对性训练,得到的模型数量和所消耗的资源都会极其庞大,现有的运维资源较难支撑。为此,在指标数据进行针对性训练阶段之前,本发明首先对数据进行聚类,这样能够使得检测处理时间大大减少,能够快速准确地处理异常。

[0056] 具体地,根据本发明的一种实施方式,在上述a步骤中,在聚类阶段,算法会使用DBSCAN来捕获待训练时序指标之间的关联关系,将形状近似、周期性相符的指标聚类。在计算指标相似度时,使用DTW(Dynamic Time Wrapping)计算指标之间的距离。DBSCAN不需要提供事先定义类别信息,并且能够通过调整聚类半径控制聚类准确度,因此在指标聚类场景中非常适用。

[0057] 图2示意性表示相同交换机采集的近似指标图。如图2所示,两条针对同一交换机不同网口的网络流量曲线,呈现出基本相同的变化趋势和规模。在实际生产环境中,同一监控单元下相同类型的数据也具有成簇特性,利用这一特点,可以大大降低模型训练阶段产生的模型数量,减少所消耗的资源,提高运维工具的性价比。此外,由于部分场景下数据数量偏少、准确度要求更高,此时单独训练数据的性价比相较预聚类更高,因此本发明将上述聚类阶段作为可选步骤。

[0058] 由上可知,在本发明中,获取时间序列数据包括获取规则的小规模时间序列数据和获取不规则的大规模时间序列数据,获取规则的小规模时间序列数据时直接训练即可,而获取不规则的大规模时间序列数据时则需要聚类处理,然后对各类时间序列数据训练,然后构建模型。

[0059] 根据本发明的一种实施方式,根据时间序列数据的类型,选取能够代表相应类型的时间序列数据的特征数据进行训练,构建模型。时间序列数据具有不同的特征。例如,百分比类型的序列数据往往呈现水平状态,在故障时会有短时间的下跌或突增;业务相关的交易序列数据往往表现为周期性的波峰/波谷,在故障时会有少量浮动;交换空间等基础设施序列数据,可能存在随时间缓慢上升的过程。因此本发明提出特征数据选择阶段,根据指标的统计信息及特点,针对性提取更契合的特征数据,从而提高模型准确率。具体的提取规则如以下表格所示:

[0060]	特征名称	适用情况
	分位值/中位数	极少出现突增或突降
	局部标准差	数据波动较少, 相同周期内不同时刻的标准差近似
	环比差分	具有一定周期性, 存在显著傅里叶频域值
	一阶差分 (ADF-test)	数据不稳定
	二阶差分	符合上述多个特性
	三阶指数平均	数据满足可预测性, 对历史数据测试时 RMSE 很小

[0061] 表2

[0062] 在本实施方式中, 表2包含了简单且有效的特征数据, 它们能够覆盖多数曲线的不同特点, 并且易于计算, 性能较好。

[0063] 根据本发明的一种实施方式, 采用RRCF选取所有特征数据进行训练, 所有特征数据经过迭代得到多个决策树, 多个决策树组成决策森林, 然后通过所述决策森林投票决定实时时间序列数据中是否存在异常数据。

[0064] 在构建所述决策树时, 所述RRCF选择切分所述特征数据的切分维度, 在所述切分

维度下, 所述RRCF选取所述特征数据的概率为 $p_i = \frac{g_i}{\sum_j g_j} + \frac{l_i}{\sum_j l_j}$, $g_i = \max_{x \in S} x_j - x_{j-1}$; 其中

i 为特征数据, p_i 表示特征 i 被选择的概率, 概率值为 0 到 1 之间; l_i 表示特征 i 在训练的样本集中, 计算得到的特征集合里, 最大值和最小值的差; g_i 表示特征 i 在训练的样本集中, 计算得到的特征集合里, 按特征大小排序后, 相邻的两个特征值之间最大的差值; $\sum g_j$ 代表每个特征维度 j 计算出来的 g_j 求和 $\sum l_j$ 代表每个特征维度 j 计算出来的 l_j 求和。

[0065] 具体地, 本发明选用的无监督异常检测基础算法是RRCF (Robust Random Cut Forest), 它的检测效果相比其他无监督异常检测算法更好, 但离实际落地使用的准确率还有一定差距。RRCF将所有的训练样本特征数据分批训练, 每一批特征数据经过多轮迭代得到一棵决策树, 所有决策树最终形成决策森林并通过投票决定是否异常。决策树构建过程中, 需要从特征数据的多个维度选择特征切分。RRCF认为在覆盖数据范围越大的维度上切分, 样本的区分效果就越好, 即特征 i 被选择的概率 $S_i = \frac{l_i}{\sum_j l_j}$, $l_i = \max_{x \in S} x_i - \min_{x \in S} x_i$, 其中,

S_i 表示特征 i 被选择的概率, l_i 表示特征 i 中最大值和最小值之间的差, S 表示训练样本集合, x_i 表示 S 中的一个样本计算出的特征 i 的值。但这种做法没有考虑维度本身分布的影响。

根据本发明的一种实施方式,在构建决策树、选择用于切分树枝的维度时,除了考虑维度本身数据的覆盖范围,还将数据的极差作为影响因子,即本发明选择特征*i*的概率

$p_i = \frac{g_i}{\sum_j g_j} + \frac{l_i}{\sum_j l_j}$, 其中 $g_i = \max_{x \in S} x_j - x_{j-1}$ 。因此,每个维度内数据分布的最大间隔越大,则

在该间隔处切分所提供的区分度更高,从而更加有效地选择切分维度,提高模型准确率。

[0066] 进一步地,在构建决策树时,每轮迭代确定切分维度后,需要在该维度的数据上选择一个合适的分界点,并据此划分左右子树。RRCF将维度数据等分后,随机选择一个切分点,没有考虑维度的分布特征。根据本发明的一种实施方式,RRCF将切分维度上的特征数据等分,等分为*N*个间隔 $[l_0, h_0, l_1, h_1, \dots, l_{N-1}, h_{N-1}]$, 并计算每个间隔的密度 $d_i = \text{Count}(p, p \in [l_i, h_i])$, 其中每个间隔被选择的概率为 $\frac{d_i}{\sum_j d_j}$, 最终从被选择的间隔中随机挑选切分点 $X_i \sim$

$\text{Uniform}[l_i, h_i]$ 。其中, l_0 和 h_{N-1} 分别代表针对训练集求解的特征维度中, l_0 表示特征的最小值, h_{N-1} 代表特征的最大值,两者作差,除以*N*,等分为*N*个间隔。例如第*i*个间隔的左端点和右端点分别是 l_i 和 h_i 。这样的选择策略能够更精准识别到切分维度的稀疏部分,从而提高区分度。在本实施方式中, d_i 代表间隔的密度,指在该范围内的样本数量。由于间隔宽度相同,样本数量越多,则密度越大。Count表示计数, p 代表落入间隔中的每一个样本,即统计 $[l_i, h_i]$ 区间范围内的样本数量。 $\text{Uniform}[l_i, h_i]$ 代表对区间 l_i, h_i 做归一化, X_i 是归一化后区间中随机选取的一个切分点。

[0067] 进一步地,存在异常数据时,利用切分点(特定节点)计算异常数据的异常分数CoDisp,计算异常分数CoDisp时,计算切分点的兄弟子树和父亲子树所包含异常数据数量的比例 $\text{CoDisp}_{\text{Node}}$,该比例越高则说明该异常数据的离群度越高。由于每个异常数据的计算过程会涉及到多个特征数据,因此模型会从初始节点逐步上移检测,重复多轮迭代后,选择最大的比例 $\text{CoDisp}_{\text{Node}}$,异常数据 x_i 的异常分数为 $\text{CoDisp}_{x_i} = \overline{\text{CoDisp}_T}, T \in \text{forest}$ 。异常分数 CoDisp_{x_i} 是指 x_i 样本计算出的异常程度。首先, x_i 会落到决策树中的一个叶子样本,算法会从这个叶子开始向上搜索,直到找到一个树枝节点Node,这个Node所代表的子树的样本量,远远小于它的兄弟子树的样本量。最终样本 x_i 的CoDisp是整个森林中,每一棵树内Node节点对应样本的CoDisp的均值。在本实施方式中,选择最大的比例 $\text{CoDisp}_{\text{Node}}$,考虑到节点所处的深度,在树中越深的节点,越正常。因此找到样本的分界点,在该处 x_i 所属的子树和其他大量样本被隔离开,更具有代表性。

[0068] 进一步地,在上述*b*步骤中,推荐部分异常数据为选择异常数据中最异常的多个片段,获取多个片段的标注后进行推荐;或者

[0069] 推荐部分异常数据为选择异常数据中最不确定的多个片段,获取多个片段的标注后进行推荐;或者

[0070] 推荐部分异常数据为根据异常分数将异常数据切分为多组,每组获取多个片段,获取片段的标注后进行推荐。

[0071] 图3-图5示意性表示三种不同的异常片段主动推荐机制图。如图3所示,根据本发明的一种实施方式,方案A选择最异常的30个片段,获取这些异常片段的标注能够进一步肯定显式异常、降低假阳率。

[0072] 如图4所示,根据本发明的另一种实施方式,方案B选择最不确定的30个片段(即围

绕异常判定阈值附近的), 这些标注能够帮助模型明确分类边界, 提高模糊异常的识别准确率。

[0073] 如图5所示, 根据本发明的第三种实施方式, 方案C根据异常分数将异常数据切分为10组, 每组获取至多3个片段, 这些标注能够捕获例如判断反馈模块对不同异常判定条件的态度, 从而帮助模型确定最佳的阈值选择范围。

[0074] 在公开数据集的实验中, 方案A的F1-score相较其他两种方案更高, 但另外两种方案各自拥有特定的适用场景。

[0075] 进一步地, 本发明通过多种技术改进了模型在线检测阶段的处理效率, 并使模型具备了根据用户反馈动态调整的能力。本发明在在线检测阶段, 仅挑选极端异常值作为自动模型反馈数据, 用来动态调整RRCF模型, 降低了模型更新频率, 提高检测性能。根据本发明的一种实施方式, 模型获取n个标注片段的异常数据后会和模型决策森林中的m棵树共同组成异常分数矩阵 $CoDisp_M[x_i][tree_j]$, 对于每个异常数据 x_i , 若用户标记为真阳, 则树 $tree_j$ 的权重 $tw_j = tw_j + \delta \times CoDisp_M[x_i][tree_j]$ 。反馈对模型的自我修正, 能够帮助模型筛选出质量更高的决策树, 这些树在后期的异常判定中会具有更高的权重, 选择更高权重的决策树, 从而优化模型, 从而提升对检测结果的影响力。

[0076] 不仅如此, 本发明还提供一种实现上述时间序列异常处理方法的时间序列异常处理装置, 如图6所示, 该装置包括:

[0077] 数据处理模块, 用于获取时间序列数据, 对时间序列数据训练, 构建模型;

[0078] 异常数据检测推荐模块, 根据所述模型检测实时获得的时间序列数据中是否存在异常数据, 若存在, 则推荐部分异常数据;

[0079] 异常数据判断反馈模块, 判断所述部分异常数据是否合理, 然后反馈判断结果;

[0080] 模型优化模块, 根据所述反馈判断结果优化所述模型, 然后继续检测实时时间序列数据。

[0081] 根据本发明的一种实施方式, 还包括:

[0082] 数据分类处理模块, 用于获取不规则的大规模时间序列数据, 对所有时间序列数据聚类处理, 然后对各类时间序列数据训练, 构建模型。

[0083] 在本发明中, 数据处理模块获取时间序列数据包括获取规则的小规模时间序列数据和获取不规则的大规模时间序列数据, 获取不规则的大规模时间序列数据时, 对所有时间序列数据聚类处理, 然后对各类时间序列数据训练, 构建模型。

[0084] 聚类处理是通过DBSCAN来捕获待训练时间序列数据之间的关联关系, 将形状近似和周期性相符的数据聚类。

[0085] 在所述聚类处理过程中, 在计算时间序列数据的近似度时, 使用动态时间规整(DTW)计算时间序列数据之间的距离。

[0086] 数据分类处理模块根据时间序列数据的类型, 选取能够代表相应类型的时间序列数据的特征数据进行训练, 构建模型。

[0087] 根据本发明的一种实施方式, 异常数据检测推荐模块采用RRCF选取所有特征数据进行训练, 所有特征数据经过迭代得到多个决策树, 多个决策树组成决策森林, 然后通过决策森林投票决定实时时间序列数据中是否存在异常数据。

[0088] 在本实施方式中, 在构建所述决策树时, 所述RRCF选择切分所述特征数据的切分

维度,在所述切分维度下,所述RRCF选取所述特征数据的概率为 $p_i = \frac{g_i}{\sum_j g_j} + \frac{l_i}{\sum_j l_j}$, $g_i =$

$\max_{x \in S} x_j - x_{j-1}$;其中*i*为特征数据, p_i 表示特征*i*被选择的概率,概率值为0到1之间; l_i 表示特征*i*在训练的样本集中,计算得到的特征集合里,最大值和最小值的差; g_i 表示特征*i*在训练的样本集中,计算得到的特征集合里,按特征大小排序后,相邻的两个特征值之间最大的差值; $\sum_j g_j$ 代表每个特征维度*j*计算出来的 g_j 求和 $\sum_j l_j$ 代表每个特征维度*j*计算出来的 l_j 求和。

[0089] 在本实施方式中,RRCF将切分维度上的特征数据等分,等分为*N*个间隔 $[l_0, h_0, l_1, h_1, \dots, l_{N-1}, h_{N-1}]$,并计算每个间隔的密度 $d_i = \text{Count}(p, p \in [l_i, h_i])$,其中每个间隔被选择的概率为 $\frac{d_i}{\sum_j d_j}$,最终从被选择的间隔中随机挑选切分点 $X_i \sim \text{Uniform}[l_i, h_i]$ 。其中, l_0 和 h_{N-1}

分别代表针对训练集求解的特征维度中, l_0 表示特征的最小值, h_{N-1} 代表特征的最大值,两者作差,除以*N*,等分为*N*个间隔。

[0090] 存在异常数据时,利用切分点计算异常数据的异常分数CoDisp,计算异常分数CoDisp时,计算切分点的兄弟子树和父亲子树所包含异常数据数量的比例 $\text{CoDisp}_{\text{Node}}$,选择最大的比例 $\text{CoDisp}_{\text{Node}}$,异常数据 x_i 的异常分数为 $\text{CoDisp}_{x_i} = \overline{\text{CoDisp}_T}, T \in \text{forest}$ 。

[0091] 在本发明中,异常数据检测推荐模块推荐部分异常数据为选择异常数据中最异常的多个片段,获取多个片段的标注后进行推荐;或者

[0092] 推荐部分异常数据为选择异常数据中最不确定的多个片段,获取多个片段的标注后进行推荐;或者

[0093] 推荐部分异常数据为根据异常分数将异常数据切分为多组,每组获取多个片段,获取片段的标注后进行推荐。

[0094] 根据本发明的一种实施方式,模型获取*n*个标注片段的异常数据后与模型的决策森林中的*m*棵决策树共同组成异常分数矩阵 $\text{CoDisp_M}[x_i][\text{tree}_j]$,对于每个异常数据 x_i ,若反馈判断结果为真阳,则决策树 tree_j 的权重为 $\text{tw}_j = \text{tw}_j + \delta \times \text{CoDisp_M}[x_i][\text{tree}_j]$,根据反馈判断结果选择更高权重的决策树,从而优化模型。

[0095] 为实现上述发明目的,本发明还提供一种电子设备,该电子设备包括:处理器、存储器及存储在所述存储器上并可在所述处理器上运行的计算机程序,计算机程序被处理器执行时实现上述时间序列异常处理方法。

[0096] 为实现上述发明目的,本发明还提供一种计算机可读存储介质,计算机可读存储介质上存储计算机程序,计算机程序被处理器执行时实现上述时间序列异常处理方法。

[0097] 根据本发明的上述方案,本发明提出了一个无监督的、白盒的、准确的时间序列异常处理方法,配合主动学习,能够主动、高效收集反馈信息。该方法在传统无监督学习框架的基础上,引入了主动学习阶段,向判断反馈部分(例如判断反馈模块或者运维人员)主动推荐异常并获取反馈,进而修正模型,提高准确率。本发明保留了传统无监督学习在调参、标注方面的优势,针对性设计了标注反馈应用策略,进一步优化了模型的召回率、检测速度和容量。

[0098] 不仅如此,本发明的处理方法对数据没有明显的偏向性,能够适配具有特定场景语义的指标,能应对非传统互联网领域的运维需求,具有更高的可扩展性,具有普适性,给

出的异常结果能够给出具体的异常原因。

[0099] 而且,在1个公开数据集和2个商业银行实际生产环境的时间序列数据上经过测试,本发明能够准确地检测并解释异常,最终在两个数据集上达到了0.81和0.89的F1-score。本发明的处理方法表现的比现有方法更好,相比传统无监督异常处理方法,最佳F1-score在两个数据集上提升了0.19到0.5不等,检测时间缩短了58%。

[0100] 本领域普通技术人员可以意识到,结合本文中所公开的实施例描述的模块及算法步骤,能够以电子硬件、或者计算机软件和电子硬件的结合来实现。这些功能究竟以硬件还是软件方式来执行,取决于技术方案的特定应用和设计约束条件。专业技术人员可以对每个特定的应用来使用不同方法来实现所描述的功能,但是这种实现不应认为超出本发明的范围。

[0101] 所属领域的技术人员可以清楚地了解到,为描述的方便和简洁,上述描述的装置和设备的具体工作过程,可以参考前述方法实施例中的对应过程,在此不再赘述。

[0102] 在本申请所提供的实施例中,应该理解到,所揭露的装置和方法,可以通过其它的方式实现。例如,以上所描述的装置实施例仅仅是示意性的,例如,所述模块的划分,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式,例如多个模块或组件可以结合或者可以集成到另一个系统,或一些特征可以忽略,或不执行。另一点,所显示或讨论的相互之间的耦合或直接耦合或通信连接可以是通过一些接口,装置或模块的间接耦合或通信连接,可以是电性,机械或其它的形式。

[0103] 所述作为分离部件说明的模块可以是或者也可以不是物理上分开的,作为模块显示的部件可以是或者也可以不是物理模块,即可以位于一个地方,或者也可以分布到多个网络模块上。可以根据实际的需要选择其中的部分或者全部模块来实现本发明实施例方案的目的。

[0104] 另外,在本发明实施例中的各功能模块可以集成在一个处理模块中,也可以是各个模块单独物理存在,也可以两个或两个以上模块集成在一个模块中。

[0105] 所述功能如果以软件功能模块的形式实现并作为独立的产品销售或使用,可以存储在一个计算机可读取存储介质中。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备)执行本发明各个实施例节能信号发送/接收的方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、ROM、RAM、磁碟或者光盘等各种可以存储程序代码的介质。

[0106] 以上描述仅为本申请的较佳实施例以及对所运用技术原理的说明。本领域技术人员应当理解,本申请中所涉及的发明范围,并不限于上述技术特征的特定组合而成的技术方案,同时也应涵盖在不脱离所述发明构思的情况下,由上述技术特征或其等同特征进行任意组合而形成的其它技术方案。例如上述特征与本申请中公开的(但不限于)具有类似功能的技术特征进行互相替换而形成的技术方案。

[0107] 应理解,本发明的发明内容及实施例中各步骤的序号的大小并不绝对意味着执行顺序的先后,各过程的执行顺序应以其功能和内在逻辑确定,而不对本发明实施例的实施过程构成任何限定。



图1




图2



图3




图4




图5




图6