



(12) 发明专利

(10) 授权公告号 CN 113962273 B

(45) 授权公告日 2022. 03. 18

(21) 申请号 202111102855.1

G06N 3/08 (2006.01)

(22) 申请日 2021.09.22

G06F 11/34 (2006.01)

(65) 同一申请的已公布的文献号

审查员 范玉霞

申请公布号 CN 113962273 A

(43) 申请公布日 2022.01.21

(73) 专利权人 北京必示科技有限公司

地址 100083 北京市海淀区东升大厦B座
516室

(72) 发明人 沈梦家 曹立 隋楷心 刘大鹏
张文池

(74) 专利代理机构 北京中知法苑知识产权代理
有限公司 11226

代理人 李慧

(51) Int. Cl.

G06K 9/62 (2022.01)


权利要求书3页 说明书7页 附图2页

(54) 发明名称

一种基于多指标的时间序列异常检测方法、
系统及存储介质

(57) 摘要

本发明提供一种基于多指标的时间序列异常检测方法、系统及存储介质,方法包括以下步骤:基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;构建基于多指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测;基于调用边的异常检测结果,生成异质故障图。通过融合多指标的关联特征,相比于现有技术存在的仅针对单一指标进行异常检测的误报率高的技术问题,本发明有效提高了异质拓扑结构中调用边的指标异常检测的正确率。



1. 一种基于多指标的时间序列异常检测方法,其特征在于,包括以下步骤:

S1 基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;

S2构建基于多指标的时间序列异常检测模型,对所述全局异质拓扑图的调用边进行异常检测;

S3 基于所述调用边的异常检测结果,生成异质故障图;

异常检测获得所有节点的融合特征,所述融合特征基于的关联权重通过多个节点注意力值的指数函数的比确定;

所述S2还包括以下步骤:

S2.1 对n个指标对应的时间窗口的时间序列进行归一化;

S2.2 通过图注意力机制学习节点的融合特征;

S2.3 基于获得的所有节点的融合特征 h_i ,学习获得不同指标对应的时间序列的嵌入特征;

S2.4 基于获得的所述不同指标对应的时间序列的所述嵌入特征,得到所有指标的时间序列在t时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

S2.5 基于得到的所有所述指标的时间序列在t时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$,

算获得代表指标偏离程度的异常分数值scorei(t);

S2.6 基于获得的所述异常分数值scorei(t),判断所述调用边是否异常。

2. 一种如权利要求1所述的基于多指标的时间序列异常检测方法,其特征在于,所述调用边是由交易明细数据和设定的时间粒度聚合生成的时间序列指标数据,所述指标数据至少包括交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间中的两种或多种的组合。

3. 一种如权利要求1所述的基于多指标的时间序列异常检测方法,其特征在于,所述基于多指标的时间序列异常检测模型通过图注意力机制构建。

4. 一种如权利要求1所述的基于多指标的时间序列异常检测方法,其特征在于,所述S2.2包括:节点 v_i 的融合特征 h_i 通过如下公式计算:

$$h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} V_j \right)$$

其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示sigmoid 激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重 α_{ij} ,节点 V_j 表示第j个指标对应的w维特征向量,关联权重 α_{ij} 通过以下公式计算:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})}$$

$$e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$$

其中, e_{ij} 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{il} 表示节点 v_i 和节点 v_l 之间的调用边的注意力值, $\oplus$ 表示特征连接操作, LeakyReLU 为激活函数, W 表示可学习的参数矩阵, L 表示 v_j 节点的邻居节点数量, l 表示 v_i 节点的邻居节点的序号。

5. 一种如权利要求1所述的基于多指标的时间序列异常检测方法, 其特征在于, 所述 S2.4 包括:

将所有所述指标的所述嵌入特征输入到多层感知机MLP中得到所有时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$; 采用均方差损失函数 MSE 作为优化函数:

$$L_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i^{(t)} - v_i^{(t)})^2}$$

其中, n 表示预测的指标的个数。

6. 一种如权利要求1所述的基于多指标的时间序列异常检测方法, 其特征在于, 所述 S2.5 包括: 对于第 i 个指标的偏离值通过以下公式计算:

$$\text{err}_i^{(t)} = |\hat{v}_i^{(t)} - v_i^{(t)}|$$

通过以下公式对指标的偏离值进行标准化:

$$\text{score}_i(t) = \frac{\text{err}_i^{(t)} - \tilde{\mu}_i}{\tilde{\sigma}_i}$$

其中, $\text{score}_i(t)$ 为异常分数值, $\tilde{\mu}$ 和 $\tilde{\sigma}$ 分别表示中位数和四分位数。

7. 一种如权利要求1所述的基于多指标的时间序列异常检测方法, 其特征在于, 所述 S2.6 包括: 将获得的代表指标的偏离程度的所述异常分数值 $\text{score}_i(t)$ 与预设的阈值相比, 当所述异常分数值 $\text{score}_i(t)$ 大于所述阈值时, 判定所述调用边的检测结果为异常。

8. 一种基于多指标的时间序列异常检测系统, 其特征在于, 包括以下模块:

全局异质拓扑图生成模块, 用于基于CMDB服务调用对照表, 构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图;

异常检测模块, 用于构建基于多指标的时间序列异常检测模型, 对所述全局异质拓扑图的调用边进行异常检测;

异质故障图生成模块, 用于基于所述调用边的异常检测结果, 生成异质故障图

所述异常检测模块被配置为执行:

S2.1 对 n 个指标对应的时间窗口的时间序列进行归一化;

S2.2 通过图注意力机制学习节点的融合特征;

S2.3 基于获得的所有节点的融合特征 H_i , 学习获得不同指标对应的时间序列的嵌入特征;

S2.4 基于获得的所述不同指标对应的时间序列的所述嵌入特征, 得到所有指标的时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

S2.5 基于得到的所有所述指标的时间序列在 t 时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$, 计算获得代表指标偏离程度的异常分数值 $\text{score}_i(t)$;

S2.6 基于获得的所述异常分数值 $\text{score}_i(t)$, 判断所述调用边是否异常。

9. 一种存储介质, 其特征在于, 其存储有计算机程序; 当所述计算机程序被计算机设备中的处理器执行时, 计算机设备执行如权利要求1-7任一项所述的方法。

一种基于多指标的时间序列异常检测方法、系统及存储介质

技术领域

[0001] 本发明涉及时间序列的异常检测,尤其涉及基于多指标的时间序列的异常检测。

背景技术

[0002] 随着云计算、服务计算等技术的快速发展和社会生产对业务需求量的与日俱增,越来越多现代化企业将应用程序和系统服务部署在云计算环境中,称为分布式云应用程序或微服务。相比于传统集中式架构,分布式架构中具备更好的组件扩展性、更高的开发生产力和更低的成本。

[0003] 为了保证系统的高可用性和可靠性,应用程序提供商必须部署链路监控系统来采集每个服务的关键性能指标,例如网络响应时间、服务响应率和成功率等,以此来处理复杂的分布式环境以满足可用性限制和严格的服务级别目标。

[0004] 其中,为保证系统正常运行,通常要针对分布式环境进行运维时间序列的异常检测。然而,目前大部分异常检测算法仅针对单一指标进行异常检测及触发告警,未考虑多个关键性能指标间存在的复杂依赖关系,因此现有的异常检测算法非常容易造成误报,尤其在异质拓扑结构中较细粒度的调用边的指标异常检测场景中,误报率较高。

发明内容

[0005] 为了解决现有技术中仅针对单一指标进行异常检测导致误报率高的技术问题,本发明提出一种基于多指标的时间序列异常检测方法、系统及存储介质,通过融合多指标关联特征,有效提高检测异质拓扑结构中调用边的指标异常检测的正确率。本发明提供:

[0006] 一种基于多指标的时间序列异常检测方法,包括以下步骤:

[0007] S1 基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0008] S2构建基于多指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。

[0009] S3 基于调用边的异常检测结果,生成异质故障图;

[0010] 异常检测获得所有节点的融合特征,所述融合特征基于的关联权重通过多个节点注意力值的指数函数的比确定。

[0011] 一种基于多指标的时间序列异常检测系统,包括以下模块:

[0012] 全局异质拓扑图生成模块,用于基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0013] 异常检测模块,用于构建基于多指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。

[0014] 局部异质拓扑图,用于基于调用边的异常检测结果,生成异质故障图。

[0015] 一种存储介质,其存储有计算机程序;当所述计算机程序被计算机设备中的处理器执行时,计算机设备执行如上述任一项所述的方法。

[0016] 本发明通过融合多指标的关联特征,构建基于多指标的时间序列异常检测模型,实现全局异质拓扑图的调用边的异常检测,相比于现有技术存在的仅针对单一指标进行异常检测导致的误报率高的技术问题,本发明有效提高了异质拓扑结构中调用边的指标异常检测的正确率。

附图说明

[0017] 为了更清楚地说明发明实施例或现有技术中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是发明的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0018] 图1 本发明的系统、服务码调用关系的全局异质拓扑图

[0019] 图2 本发明的方法流程图

[0020] 图3 本发明的基于多指标的时间序列异常检测模型

[0021] 图4 本发明的指标异常检测结果示意图

[0022] 图5 本发明的异质故障图。

具体实施方式

[0023] 为了能够更清楚地理解本发明的上述目的、特征和优点,下面结合附图和具体实施方式对本发明进行进一步的详细描述。需要说明的是,在不冲突的情况下,本申请的实施例及实施例中的特征可以相互组合。

[0024] 在下面的描述中阐述了很多具体细节以便于充分理解本发明,但是,本发明还可以采用其他不同于在此描述的方式来实施,因此,本发明的保护范围并不受下面公开的具体实施例的限制。

[0025] 实施例一

[0026] 当前大型企业多采用微服务架构和企业服务总线的架构设计,系统和服务间的复杂调用关系难以形式化表示,尤其是在系统日志中缺少全局流水号的情况下。基于此,本发明通过构建包括系统间调用关系、服务码间调用关系的异质拓扑图来清晰地表达业务间的调用关系。相对于现有技术仅针对系统间调用关系的调用拓扑结构图,本发明的异质拓扑图的表示形式更加清晰,能够捕捉到更细粒度的服务码间的调用关系和隶属关系。

[0027] 为了解耦系统和服务间的调用依赖,金融证券等企业一般使用企业服务总线系统 ESB_F5 来对业务请求进行转发和负载均衡,因此在监控系统的日志数据中难以得到上下游服务码间直接的调用关系。为了定位到更细粒度的服务码级别异常和根因,本发明提出了服务码和应用系统间混合关系的构图策略。此外,如果是存在 ESB_F5 转发的系统调用,可以通过整理 CMDB 服务调用对照表来获取上下游系统中的服务码调用关系和服务码隶属关系。下面以实际样例数据来描述调用异质图谱特征图的构建过程。

[0028] 业务监控系统在日志中详细采集业务交易的调用数据及其状态,例如某个告警时刻的调用日志解析后如下表 1 所示:

[0029]

时间	调用方	接收方	服务码	是否响应	是否成功	响应时间
2021-05-10 10:00:01.133	S1	S4	T1	否	否	200ms

2021-05-10 10:00:03.224	S2	S4	T1	否	否	300ms
...	...	...	...	...	...	...
2021-05-10 10:00:06.453	S3	S4	T2	是	是	10ms

[0030] 表 1. 解析后的交易明细数据

[0031] 可以看出此时数据中包含系统节点 S1,S2,S3,S4 及其调用的服务码节点 T1,T2。全面考虑节点间存在的调用关系,构建得到系统、服务码调用关系的异质拓扑图如图1所示,图1得到的是包括全局业务服务码、系统间的调用关系图,其中每条调用边是由交易明细数据和设定的时间粒度聚合生成的时间序列指标数据,本发明采用的指标至少包括:交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间。

[0032] 由于实际业务中业务量庞大且非常复杂,所以得到的全局异质拓扑图往往非常复杂。但在实际生产环境中发生故障时仅局部业务会受到影响,因此需要对全局异质拓扑图进行调用边的异常检测来得到发生故障的异质故障图。

[0033] 针对现有技术仅针对单一指标进行异常检测算法误报率高的技术问题,本实施例提供一种基于多指标的时间序列异常检测方法,其流程图如图2所示,包括以下步骤:

[0034] S1 基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0035] 其中,全局异质拓扑图的每条调用边是由交易明细数据和设定的时间粒度聚合生成的时间序列指标数据,本发明采用的指标数据至少包括:交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间中的两种或多种的组合。

[0036] S2构建基于多指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。

[0037] 其中,基于多指标的时间序列异常检测模型如图3所示,通过图注意力机制构建。S2具体包括以下步骤:

[0038] S2.1 对n个指标对应的时间窗口的时间序列进行归一化;

[0039] 其中,n表示每个调用边统计的KPI指标的个数,为考虑所有指标间的关联特征,将上述n个KPI指标转化为节点进行表示,即第i个指标对应节点 v_i 。采用min-max归一化方法,得到n个KPI指标对应的输入特征 $\{v_1, v_2, \dots, v_n\}$,其中 $v_i \in \mathbb{R}^w$, 节点 v_i 表示第i个KPI指标对应的w维特征向量,特征向量的维度w与时间窗口的维度相对应。

[0040] S2.2 通过图注意力机制学习节点的融合特征。

[0041] 节点 v_i 的融合特征 h_i 通过如下公式计算:

$$[0042] \quad h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} V_j \right)$$

[0043] 其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示sigmoid 激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重,节点 V_j 表示第j 个指标对应的 w维特征向量,关联权重 α_{ij} 通过以下公式计算:

$$[0044] \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})}$$

[0045]
$$e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$$

[0046] 其中, e_{ij} 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{i1} 表示节点 v_i 和节点 v_1 之间的调用边的注意力值, $\oplus$ 表示特征连接操作, LeakyReLU 为激活函数, W 表示可学习的参数矩阵, L 表示 v_j 节点的邻居节点数量, l 表示 v_i 节点的邻居节点的序号。

[0047] 计算得到所有节点的融合特征, 用 H_i 表示。

[0048] S2.3 基于获得的所有节点的融合特征 H_i , 学习获得不同指标对应的时间序列的嵌入特征。

[0049] 经过图注意力机制学习后, 所有节点的融合特征 H_i 的输出特征维度为 $n \times w$, 将其与原始序列特征相连得到 $n \times 2w$ 维特征, 然后再输入到 LSTM 模块中编码长期时序依赖特征, 学习获得不同指标对应的时间序列的嵌入特征。

[0050] S2.4 基于获得的所述不同指标对应的时间序列的所述嵌入特征, 得到所有指标的时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

[0051] 具体的, 将所有所述指标的所述嵌入特征输入到多层感知机MLP中得到所有时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$; 采用均方差损失函数 MSE 作为优化函数:

[0052]
$$L_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i^{(t)} - v_i^{(t)})^2}$$

[0053] 其中, n 表示预测的指标的个数。

[0054] S2.5 基于得到的所有所述指标的时间序列在 t 时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$, 计算获得代表指标偏离程度的异常分数值 $\text{score}_i(t)$ 。

[0055] 其中, 对于第 i 个指标的偏离值通过以下公式计算:

[0056]
$$\text{err}_i^{(t)} = |\hat{v}_i^{(t)} - v_i^{(t)}|$$

[0057] 通过以下公式对指标的偏离值进行标准化:

[0058]
$$\text{score}_i(t) = \frac{\text{err}_i^{(t)} - \tilde{\mu}_i}{\tilde{\sigma}_i}$$

[0059] 其中, $\text{score}_i(t)$ 为异常分数值, $\tilde{\mu}$ 和 $\tilde{\sigma}$ 分别表示中位数和四分位数而不是均值和标准差, 实验证明, 上述归一化效果表现效果最优。通过采用基于多指标的时间序列异常检测模型, 本发明可以更加直观的观察每个指标的偏离程度。

[0060] S2.6 基于获得的所述异常分数值 $\text{score}_i(t)$, 判断所述调用边是否异常。

[0061] 具体的, 将获得的代表指标的偏离程度的所述异常分数值 $\text{score}_i(t)$ 与预设的阈值相比, 当所述异常分数值 $\text{score}_i(t)$ 大于所述阈值时, 判定所述调用边的检测结果为异常。检测结果如图4所示, 红色边表示异常, 黑色边表示正常。

[0062] 相比于传统的时间序列异常检测方法, 本发明构建的基于多指标的时间序列异常检测模型不依赖于任何数据分布的假设, 而且考虑了业务调用的多指标间的关联依赖特

征,使得异常检测更加准确和高效。

[0063] S3 基于每条调用边的异常检测结果,生成异质故障图。

[0064] 通过S2对异质拓扑图中调用边的多指标进行异常检测,本发明得到异质拓扑图中的异常调用边。具体的,根据异常检测结果从全局异质拓扑图中过滤掉检测结果为正常的调用边数据,可以得到仅显示发生故障部分的异质故障图。例如,对图 1 的全局异质拓扑图过滤后得到如图 5 所示的异质故障图。上述异质故障图可进一步用于交易码的根源故障定位等,在有效提高定位准确性的基础上可以有效减少计算时间。

[0065] 实施例二

[0066] 本实施例提供一种基于多指标的时间序列异常检测系统,包括以下模块:

[0067] 全局异质拓扑图生成模块,用于基于CMDB服务调用对照表,构建包括系统间调用关系和服务码间调用关系的全局异质拓扑图。

[0068] 其中,全局异质拓扑图的每条调用边是由交易明细数据和设定的时间粒度聚合生成的时间序列指标数据,本发明采用的指标数据至少包括:交易量、成功量、响应量、失败量、未响应量、成功率、响应率、响应时间中的两种或多种的组合。

[0069] 异常检测模块,用于构建基于多指标的时间序列异常检测模型,对全局异质拓扑图的调用边进行异常检测。

[0070] 其中,异常检测模型如图3所示,通过图注意力机制构建。异常检测模块具体用于实现以下功能:

[0071] 首先对 n 个指标对应的时间窗口的时间序列进行归一化。

[0072] 其中, n 表示每个调用边统计的KPI指标的个数,为考虑所有指标间的关联特征,将上述 n 个KPI指标转化为节点进行表示,即第 i 个指标对应节点 v_i 。采用min-max归一化方法,得到 n 个KPI指标对应的输入特征 $\{v_1, v_2, \dots, v_n\}$,其中 $v_i \in \mathbb{R}^w$, 节点 v_i 表示第 i 个KPI指标对应的 w 维特征向量,特征向量的维度 w 与时间窗口的维度相对应。

[0073] 通过图注意力机制学习不同节点的融合特征。

[0074] 具体的,节点 v_i 的融合特征 h_i 通过如下公式计算:

$$[0075] \quad h_i = \sigma \left(\sum_{v_j \in N(i)} \alpha_{ij} V_j \right)$$

[0076] 其中, $N(i)$ 表示节点 v_i 的邻居节点的集合, v_j 表示节点 v_i 的邻居节点, σ 表示sigmoid 激活函数, α_{ij} 表示节点 v_i 和节点 v_j 的关联权重,节点 V_j 表示第 j 个指标对应的 w 维特征向量,关联权重 α_{ij} 通过以下公式计算:

$$[0077] \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{l=1}^L \exp(e_{il})}$$

$$[0078] \quad e_{ij} = \text{LeakyReLU} \left(W^T \cdot (v_i \oplus v_j) \right)$$

[0079] 其中, e_{ij} 表示节点 v_i 和节点 v_j 之间的调用边的注意力值, e_{i1} 表示节点 v_i 和节点 v_1 之间的调用边的注意力值, $\oplus$ 表示特征连接操作,LeakyReLU为激活函数, W 表示可学习的参

数矩阵, L 表示 v_j 节点的邻居节点数量, l 表示 v_i 节点的邻居节点的序号。计算得到所有节点的融合特征, 用 H_i 表示。

[0080] 基于获得的所有节点的融合特征 H_i , 学习获得不同指标对应的时间序列的嵌入特征。

[0081] 经过图注意力机制学习后, 所有节点的融合特征 H_i 的输出特征维度为 $n \times w$, 将其与原始序列特征相连得到 $n \times 2w$ 维特征, 然后再输入到 LSTM 模块中编码长期时序依赖特征, 学习获得不同指标对应的时间序列的嵌入特征。

[0082] 基于获得的所述不同指标对应的时间序列的所述嵌入特征, 得到所有指标的时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$;

[0083] 具体的, 将所有所述指标的所述嵌入特征输入到多层感知机 MLP 中得到所有时间序列在 t 时刻的预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$; 采用均方差损失函数 MSE 作为优化函数:

$$[0084] \quad L_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{v}_i^{(t)} - v_i^{(t)})^2}$$

[0085] 其中, n 表示预测的指标的个数。本发明采用基于多指标的时间序列异常检测模型, 可以更加直观的观察每个指标的偏离程度。

[0086] 基于得到的所有所述指标的时间序列在 t 时刻的所述预测值 $\{\hat{v}_1^{(t)}, \hat{v}_2^{(t)}, \dots, \hat{v}_n^{(t)}\}$, 计算获得代表指标偏离程度的异常分数值 $\text{score}_i(t)$ 。

[0087] 其中, 对于第 i 个指标的偏离值通过以下公式计算:

$$[0088] \quad \text{err}_i^{(t)} = |\hat{v}_i^{(t)} - v_i^{(t)}|$$

[0089] 通过以下公式对指标的偏离值进行标准化:

$$[0090] \quad \text{score}_i(t) = \frac{\text{err}_i^{(t)} - \tilde{\mu}_i}{\tilde{\sigma}_i}$$

[0091] 其中, $\text{score}_i(t)$ 为异常分数值, $\tilde{\mu}$ 和 $\tilde{\sigma}$ 分别表示中位数和四分位数而不是均值和标准差, 实验证明, 上述归一化效果表现效果最优。通过采用基于多指标的时间序列异常检测模型, 本发明可以更加直观的观察每个指标的偏离程度。

[0092] 基于获得的所述异常分数值 $\text{score}_i(t)$, 判断所述调用边是否异常。

[0093] 具体的, 将获得的代表指标的偏离程度的所述异常分数值 $\text{score}_i(t)$ 与预设的阈值相比, 当所述异常分数值 $\text{score}_i(t)$ 大于所述阈值时, 判定所述调用边的检测结果为异常。检测结果如图4所示, 红色边表示异常, 黑色边表示正常。

[0094] 异质故障图生成模块, 用于基于调用边的异常检测结果, 生成异质故障图。

[0095] 通过基于多指标的时间序列异常检测模型对异质拓扑图中的调用边进行异常检测, 本发明得到异质拓扑图中的异常调用边。具体的, 根据异常检测结果从全局异质拓扑图中过滤掉检测结果为正常的调用边数据, 可以得到仅显示发生故障部分的异质故障图。例如, 对图 1 的全局异质拓扑图过滤后得到如图 5 所示的异质故障图。上述异质故障图可进一步用于交易码的根源故障定位等, 在有效提高定位准确性的基础上可以有效减少计算时

间。

[0096] 实施例三

[0097] 本实施例提供一种存储介质,其存储有计算机程序;当所述计算机程序被计算机设备中的处理器执行时,计算机设备执行如上述任一项所述的方法。

[0098] 本发明通过融合多指标的关联特征,构建基于多指标的时间序列异常检测模型,实现全局异质拓扑图的调用边的异常检测,相比于现有技术存在的仅针对单一指标进行异常检测导致的误报率高的技术问题,本发明有效提高了异质拓扑结构中调用边的指标异常检测的正确率。

[0099] 为了说明的目的,前述描述使用具体命名以提供对所述实施方案的透彻理解。然而,对于本领域的技术人员而言将显而易见的是,不需要具体细节即可实践所述实施方案。因此,出于例示和描述的目的,呈现了对本文所述的具体实施方案的前述描述。这些描述并非旨在是穷举性的或将实施方案限制到所公开的精确形式。对于本领域的普通技术人员而言将显而易见的是,鉴于上面的教导内容,许多修改和变型是可行的。另外,当在本文中用于指部件的位置时,上文和下文的术语或它们的同义词不一定指相对于外部参照的绝对位置,而是指部件的参考附图的相对位置。

[0100] 此外,前述附图和描述包括许多概念和特征,其可以多种方式组合以实现多种有益效果和优点。因此,可组合来自各种不同附图的特征,部件,元件和/或概念,以产生未必在本说明书中示出或描述的实施方案或实施方式。此外,在任何特定实施方案和/或实施方式中,不一定需要具体附图或说明中所示的所有特征,部件,元件和/或概念。应当理解,此类实施方案和/或实施方式落入本说明书的范围。




图1




图2




图3




图4




图5